

Metody probabilistyczne

Rozwiązania zadań

10. Ciągłe zmienne losowe II

19.12.2017

Zadanie 1. Rozważ zmienne (X, Y) o gęstości łącznej:

$$f(x, y) = \begin{cases} c(x+y) & x, y \in [0, 1] \\ 0 & \text{w przeciwnym przypadku} \end{cases}$$

Oblicz stałą c , gęstości brzegowe i warunkowe.

Odpowiedź: Korzystając z warunku normalizacji gęstości obliczamy stałą c :

$$\begin{aligned} 1 &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) \, dx \, dy = \int_0^1 \int_0^1 c(x+y) \, dx \, dy \\ &= c \int_0^1 \int_0^1 x \, dx \, dy + c \int_0^1 \int_0^1 y \, dx \, dy \\ &= c \int_0^1 \underbrace{\left(\int_0^1 dy \right)}_{=1} x \, dx + c \int_0^1 \underbrace{\left(\int_0^1 dx \right)}_{=1} y \, dy \\ &= c \frac{1}{2} x^2 \Big|_0^1 + c \frac{1}{2} y^2 \Big|_0^1 = \frac{1}{2} c + \frac{1}{2} c = c, \end{aligned}$$

z czego wynika, że $c = 1$, a więc $f(x, y) = x + y$ dla $x, y \in [0, 1]$. Wyznamy teraz gęstości brzegowe:

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) \, dy = \int_0^1 (x+y) \, dy = x \int_0^1 dy + \int_0^1 y \, dy = x + \frac{1}{2} y^2 \Big|_0^1 = x + \frac{1}{2}.$$

Z symetrii gęstości ze względu na x i y otrzymujemy również $f_Y(y) = y + \frac{1}{2}$. Wyznamy na koniec gęstości warunkowe:

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)} = \frac{x+y}{y + \frac{1}{2}}.$$

Z symetrii zagadnienia mamy również $f_{X|Y}(x|y) = \frac{x+y}{x + \frac{1}{2}}$.

Zadanie 2. Niech X_1, \dots, X_n będą niezależnymi zmiennymi losowymi o tym samym rozkładzie opisanym dystrybucją F_X . Wyznacz dystrybuanty zmiennych $Y = \max\{X_1, \dots, X_n\}$ oraz $X = \min\{X_1, \dots, X_n\}$.

Odpowiedź:

1. Dystrybuanta F_Y zmienne Y :

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(\max\{X_1, \dots, X_n\} \leq y) \\ &= P(X_1 \leq y, X_2 \leq y, \dots, X_n \leq y) \\ &\stackrel{(*)}{=} P(X_1 \leq y) \cdot P(X_2 \leq y) \cdot \dots \cdot P(X_n \leq y) = F_X(y)^n, \end{aligned}$$

gdzie w $(*)$ wykorzystaliśmy niezależność X_1, \dots, X_n .

2. Dystrybuanta F_Z zmiennej Z :

$$\begin{aligned}
 F_Z(z) &= P(Z \leq z) = 1 - P(Z > z) = 1 - P(\min\{X_1, \dots, X_n\} > z) \\
 &= 1 - P(X_1 > z, X_2 > z, \dots, X_n > z) \\
 &\stackrel{(*)}{=} 1 - P(X_1 > z) \cdot P(X_2 > z) \cdot \dots \cdot P(X_n > z) \\
 &= 1 - (1 - P(X_1 \leq z)) \cdot (1 - P(X_2 \leq z)) \cdot \dots \cdot (1 - P(X_n \leq z)) \\
 &= 1 - (1 - F_X(z))^n,
 \end{aligned}$$

gdzie w (*) wykorzystaliśmy niezależność X_1, \dots, X_n .

Zadanie 3*. Rozważ dwie niezależne zmienne losowe $X \sim N(\mu_X, \sigma_X^2)$ oraz $Y \sim N(\mu_Y, \sigma_Y^2)$. Wyznacz gęstość zmiennej $Z = X + Y$.

Odpowiedź: Gęstość f_Z zmiennej Z jest spłotem gęstości f_X i f_Y :

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(t) f_Y(z-t) dt \quad (1)$$

$$\begin{aligned}
 &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma_X^2}} \exp\left\{-\frac{(t-\mu_X)^2}{2\sigma_X^2}\right\} \frac{1}{\sqrt{2\pi\sigma_Y^2}} \exp\left\{-\frac{(z-t-\mu_Y)^2}{2\sigma_Y^2}\right\} dt \\
 &= \frac{1}{\sqrt{2\pi\sigma_X^2}} \frac{1}{\sqrt{2\pi\sigma_Y^2}} \int_{-\infty}^{\infty} \exp\left\{-\frac{(t-\mu_X)^2}{2\sigma_X^2} - \frac{(z-t-\mu_Y)^2}{2\sigma_Y^2}\right\} dt.
 \end{aligned} \quad (2)$$

Aby policzyć tę całkę, spróbujemy uprościć wykładnik (wyrażenie w exp) w (2):

$$\begin{aligned}
 -\frac{(t-\mu_X)^2}{2\sigma_X^2} - \frac{(z-t-\mu_Y)^2}{2\sigma_Y^2} &= -\frac{(t-\mu_X)^2\sigma_Y^2 + ((z-\mu_Y)-t)^2\sigma_X^2}{2\sigma_X^2\sigma_Y^2} \\
 &= -\frac{t^2(\sigma_X^2 + \sigma_Y^2) - 2t(\mu_X\sigma_Y^2 + (z-\mu_Y)\sigma_X^2) + \mu_X^2\sigma_Y^2 + (z-\mu_Y)^2\sigma_X^2}{2\sigma_X^2\sigma_Y^2}.
 \end{aligned} \quad (3)$$

Zauważmy, że w liczniku w (3) mamy wyrażenie kwadratowe (ze względu na t) postaci:

$$at^2 - 2tb + c,$$

gdzie:

$$a = \sigma_X^2 + \sigma_Y^2, \quad b = \mu_X\sigma_Y^2 + (z-\mu_Y)\sigma_X^2, \quad c = \mu_X^2\sigma_Y^2 + (z-\mu_Y)^2\sigma_X^2 \quad (4)$$

Chcielibyśmy je zamienić na bardziej zwartą postać $a(t-d)^2 + r$. Jak znaleźć d i r ? Wystarczy oba wyrażenia przyrównać:

$$at^2 - 2tb + c = a(t-d)^2 + r = at^2 - 2tad + ad^2 + r.$$

Ponieważ wyrażenia przy kolejnych potęgach t muszą być sobie równe, dostaniemy:

$$b = ad, \quad c = ad^2 + r \quad \implies \quad d = \frac{b}{a}, \quad r = c - ad^2 = c - \frac{b^2}{a}.$$

Czyli:

$$\begin{aligned}
 d &= \frac{\mu_X\sigma_Y^2 + (z-\mu_Y)\sigma_X^2}{\sigma_X^2 + \sigma_Y^2} \\
 r &= \mu_X^2\sigma_Y^2 + (z-\mu_Y)^2\sigma_X^2 - \frac{(\mu_X\sigma_Y^2 + (z-\mu_Y)\sigma_X^2)^2}{\sigma_X^2 + \sigma_Y^2} \\
 &= \frac{\mu_X^2\sigma_Y^4 + (z-\mu_Y)^2\sigma_X^4 + \sigma_X^2\sigma_Y^2(\mu_X^2 + (z-\mu_Y)^2) - (\mu_X\sigma_Y^2 + (z-\mu_Y)\sigma_X^2)^2}{\sigma_X^2 + \sigma_Y^2} \\
 &= \frac{\sigma_X^2\sigma_Y^2(\mu_X^2 + (z-\mu_Y)^2) - 2\mu_X\sigma_Y^2(z-\mu_Y)\sigma_X^2}{\sigma_X^2 + \sigma_Y^2} \\
 &= \frac{\sigma_X^2\sigma_Y^2}{\sigma_X^2 + \sigma_Y^2} (\mu_X^2 + (z-\mu_Y)^2 - 2\mu_X(z-\mu_Y)) = \frac{\sigma_X^2\sigma_Y^2}{\sigma_X^2 + \sigma_Y^2} (z-\mu_X-\mu_Y)^2.
 \end{aligned} \quad (5)$$

Ułamek po prawej stronie równania (3) ma więc postać:

$$-\frac{a(t-d)^2 + r}{2\sigma_X^2\sigma_Y^2},$$

a tym samym całka w (2) wygląda następująco:

$$\begin{aligned} \int_{-\infty}^{\infty} \exp\left\{-\frac{a(t-d)^2 + r}{2\sigma_X^2\sigma_Y^2}\right\} dt &= \int_{-\infty}^{\infty} \exp\left\{-\frac{a(t-d)^2}{2\sigma_X^2\sigma_Y^2}\right\} \exp\left\{-\frac{r}{2\sigma_X^2\sigma_Y^2}\right\} dt \\ &= \exp\left\{-\frac{r}{2\sigma_X^2\sigma_Y^2}\right\} \int_{-\infty}^{\infty} \exp\left\{-\frac{a(t-d)^2}{2\sigma_X^2\sigma_Y^2}\right\} dt. \end{aligned} \quad (6)$$

Mając dowolny rozkład normalny o parametrach μ i σ^2 , gęstość rozkładu musi się normalizować do 1, tzn:

$$\frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\infty} \exp\left\{-\frac{(t-\mu)^2}{2\sigma^2}\right\} dt = 1,$$

z czego wynika:

$$\int_{-\infty}^{\infty} \exp\left\{-\frac{(t-\mu)^2}{2\sigma^2}\right\} dt = \sqrt{2\pi\sigma^2} \quad (7)$$

Zauważmy teraz, że całka po prawej stronie (6) jest dokładnie postaci (7), jeśli przyrównamy $\mu = d$ oraz $\sigma^2 = \frac{\sigma_X^2\sigma_Y^2}{a}$. Tym samym dostajemy:

$$\int_{-\infty}^{\infty} \exp\left\{-\frac{a(t-d)^2}{2\sigma_X^2\sigma_Y^2}\right\} dt = \sqrt{2\pi \frac{\sigma_X^2\sigma_Y^2}{a}} = \sqrt{2\pi \frac{\sigma_X^2\sigma_Y^2}{\sigma_X^2 + \sigma_Y^2}},$$

gdzie w ostatniej równości podstawiliśmy wartość a z (4). Wykorzystując definicję r z (5), dostajemy:

$$\exp\left\{-\frac{r}{2\sigma_X^2\sigma_Y^2}\right\} = \exp\left\{-\frac{\cancel{\sigma_X^2}\cancel{\sigma_Y^2}(z-\mu_X-\mu_Y)^2}{2\cancel{\sigma_X^2}\cancel{\sigma_Y^2}(\sigma_X^2+\sigma_Y^2)}\right\} = \exp\left\{-\frac{(z-\mu_X-\mu_Y)^2}{2(\sigma_X^2+\sigma_Y^2)}\right\}.$$

Możemy więc zapisać prawą stronę (6) jako:

$$\exp\left\{-\frac{(z-\mu_X-\mu_Y)^2}{2(\sigma_X^2+\sigma_Y^2)}\right\} \sqrt{2\pi \frac{\sigma_X^2\sigma_Y^2}{\sigma_X^2+\sigma_Y^2}}.$$

Podstawiając to do (2) dostajemy:

$$\begin{aligned} f_Z(z) &= \frac{1}{\sqrt{2\pi\sigma_X^2}} \frac{1}{\sqrt{2\pi\sigma_Y^2}} \exp\left\{-\frac{(z-\mu_X-\mu_Y)^2}{2(\sigma_X^2+\sigma_Y^2)}\right\} \sqrt{2\pi \frac{\sigma_X^2\sigma_Y^2}{\sigma_X^2+\sigma_Y^2}} \\ &= \sqrt{2\pi \frac{\cancel{\sigma_X^2}\cancel{\sigma_Y^2}}{\sigma_X^2+\sigma_Y^2} \frac{1}{2\pi\cancel{\sigma_X^2}} \frac{1}{2\pi\cancel{\sigma_Y^2}}} \\ &= \frac{1}{\sqrt{2\pi(\sigma_X^2+\sigma_Y^2)}} \exp\left\{-\frac{(z-\mu_X-\mu_Y)^2}{2(\sigma_X^2+\sigma_Y^2)}\right\}. \end{aligned}$$

Ale to ostatnie wyrażenie ma postać gęstości rozkładu normalnego z parametrami $\mu = \mu_X + \mu_Y$ i $\sigma^2 = \sigma_X^2 + \sigma_Y^2$. Czyli:

$$Z \sim N(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2).$$