

Metody probabilistyczne

11. Twierdzenia graniczne

Wojciech Kotłowski

Instytut Informatyki PP


<http://www.cs.put.poznan.pl/wkotlowski/>

19.12.2017

Motywacja

Rzucamy wielokrotnie uczciwą monetą i zliczamy **częstość orłów**: $\frac{\# \text{orłów}}{\# \text{rzutów}}$.


Obserwujemy zmiany tej częstości w miarę zwiększania liczby rzutów:



Motywacja

Rzucamy wielokrotnie uczciwą monetą i zliczamy **częstość orłów**: $\frac{\text{\#orłów}}{\text{\#rzutów}}$.


Obserwujemy zmiany tej częstości w miarę zwiększania liczby rzutów:



Wniosek: Częstość orłów zbiega do $\frac{1}{2}$, czyli **prawdopodobieństwa wyrzucenia orła**!


Motywacja

Podobna obserwacja dla wyników rzutu kostką (zliczamy częstość każdego wyniku $\{1, 2, 3, 4, 5, 6\}$)



Motywacja

Podobna obserwacja dla wyników rzutu kostką (zliczamy częstość każdego wyniku $\{1, 2, 3, 4, 5, 6\}$)



Częstość każdego wyniku zbiega do jego prawdopodobieństwa $\frac{1}{6} \simeq 0.167$.

Schemat Bernoulliego

X_1, \dots, X_n – niezależne zmienne o rozkładzie $B(p)$ ($X_i \in \{0, 1\}$)

- Rzuty monetą: X_i koduje reszkę/orła ($p = \frac{1}{2}$)
- Rzut kostką: X_i koduje „wypadło 6” / „nie wypadło 6” ($p = \frac{1}{6}$)

Schemat Bernoulliego

X_1, \dots, X_n – niezależne zmienne o rozkładzie $B(p)$ ($X_i \in \{0, 1\}$)

- Rzuty monetą: X_i koduje reszkę/orła ($p = \frac{1}{2}$)
- Rzut kostką: X_i koduje „wypadło 6” / „nie wypadło 6” ($p = \frac{1}{6}$)

Liczba sukcesów $S_n = X_1 + \dots + X_n$ ma rozkład dwumianowy $B(n, p)$

Schemat Bernoulliego

X_1, \dots, X_n – niezależne zmienne o rozkładzie $B(p)$ ($X_i \in \{0, 1\}$)

- Rzuty monetą: X_i koduje reszkę/orła ($p = \frac{1}{2}$)
- Rzut kostką: X_i koduje „wypadło 6” / „nie wypadło 6” ($p = \frac{1}{6}$)

Liczba sukcesów $S_n = X_1 + \dots + X_n$ ma rozkład dwumianowy $B(n, p)$

$$ES_n =$$

Schemat Bernoulliego

X_1, \dots, X_n – niezależne zmienne o rozkładzie $B(p)$ ($X_i \in \{0, 1\}$)

- Rzuty monetą: X_i koduje reszkę/orła ($p = \frac{1}{2}$)
- Rzut kostką: X_i koduje „wypadło 6” / „nie wypadło 6” ($p = \frac{1}{6}$)

Liczba sukcesów $S_n = X_1 + \dots + X_n$ ma rozkład dwumianowy $B(n, p)$

$$ES_n = np, \quad D^2(S_n) =$$

Schemat Bernoulliego





X_1, \dots, X_n – niezależne zmienne o rozkładzie $B(p)$ ($X_i \in \{0, 1\}$)

- Rzuty monetą: X_i koduje reszkę/orła ($p = \frac{1}{2}$)
- Rzut kostką: X_i koduje „wypadło 6” / „nie wypadło 6” ($p = \frac{1}{6}$)





Liczba sukcesów $S_n = X_1 + \dots + X_n$ ma rozkład dwumianowy $B(n, p)$

$$ES_n = np, \quad D^2(S_n) = np(1 - p)$$

Rozkład zmiennej S_n (dwumianowy) dla $p = \frac{1}{2}$



Rozkład zmiennej S_n (dwumianowy) dla $p = \frac{1}{2}$



Rozkład „koncentruje” się wokół $ES_n = \frac{1}{2}n$, ale ES_n i $D^2(S_n)$ rosną!

Częstość sukcesów

$$S_n \sim B(n, p) \quad ES_n = np \quad D^2(S_n) = np(1 - p)$$

Zmieniamy skalę: częstość sukcesów (średnia arytmetyczna) $\overline{X}_n = \frac{S_n}{n}$

$$E\overline{X}_n =$$

Częstość sukcesów

$$S_n \sim B(n, p) \quad ES_n = np \quad D^2(S_n) = np(1 - p)$$

Zmieniamy skalę: częstość sukcesów (średnia arytmetyczna) $\bar{X}_n = \frac{S_n}{n}$

$$E\bar{X}_n = E\left(\frac{S_n}{n}\right) = \frac{ES_n}{n} = p$$

Częstość sukcesów

$$S_n \sim B(n, p) \quad ES_n = np \quad D^2(S_n) = np(1 - p)$$

Zmieniamy skalę: częstość sukcesów (średnia arytmetyczna) $\bar{X}_n = \frac{S_n}{n}$

$$E\bar{X}_n = E\left(\frac{S_n}{n}\right) = \frac{ES_n}{n} = p$$

$$D^2(\bar{X}_n) =$$

Częstość sukcesów

$$S_n \sim B(n, p) \quad ES_n = np \quad D^2(S_n) = np(1 - p)$$

Zmieniamy skalę: częstość sukcesów (średnia arytmetyczna) $\bar{X}_n = \frac{S_n}{n}$

$$E\bar{X}_n = E\left(\frac{S_n}{n}\right) = \frac{ES_n}{n} = p$$

$$D^2(\bar{X}_n) = D^2\left(\frac{S_n}{n}\right) = \frac{D^2(S_n)}{n^2} = \frac{p(1 - p)}{n}$$

Częstość sukcesów

$$S_n \sim B(n, p) \quad ES_n = np \quad D^2(S_n) = np(1 - p)$$





Zmieniamy skalę: częstość sukcesów (średnia arytmetyczna) $\bar{X}_n = \frac{S_n}{n}$

$$E\bar{X}_n = E\left(\frac{S_n}{n}\right) = \frac{ES_n}{n} = p$$

$$D^2(\bar{X}_n) = D^2\left(\frac{S_n}{n}\right) = \frac{D^2(S_n)}{n^2} = \frac{p(1 - p)}{n}$$

$$D(\bar{X}_n) = \sqrt{\frac{p(1 - p)}{n}}$$

Rozkład zmiennej \bar{X}_n



Prawo wielkich liczb dla rozkładu dwupunktowego

Nierówność Czebyszewa – przypomnienie

Dla zmiennej losowej o skończonej wartości oczekiwanej i wariancji:

$$\forall \epsilon > 0 \quad P(|X - EX| > \epsilon) \leq \frac{D^2(X)}{\epsilon^2}$$

Prawo wielkich liczb dla rozkładu dwupunktowego

Nierówność Czebyszewa – przypomnienie

Dla zmiennej losowej o skończonej wartości oczekiwanej i wariancji:

$$\forall \epsilon > 0 \quad P(|X - EX| > \epsilon) \leq \frac{D^2(X)}{\epsilon^2}$$

Stosujemy twierdzenie do \bar{X}_n :

$$P(|\bar{X}_n - p| > \epsilon) \leq \frac{p(1-p)}{n\epsilon^2}$$

$$E\bar{X}_n = p$$

$$D^2(\bar{X}_n) = \frac{p(1-p)}{n}$$

Prawo wielkich liczb dla rozkładu dwupunktowego

Nierówność Czebyszewa – przypomnienie

Dla zmiennej losowej o skończonej wartości oczekiwanej i wariancji:

$$\forall \epsilon > 0 \quad P(|X - EX| > \epsilon) \leq \frac{D^2(X)}{\epsilon^2}$$

Stosujemy twierdzenie do \bar{X}_n :

$$P(|\bar{X}_n - p| > \epsilon) \leq \frac{p(1-p)}{n\epsilon^2}$$

Szansa odchylenia się częstości o więcej niż ϵ od prawdopodobieństwa sukcesu maleje z n

Prawo wielkich liczb dla rozkładu dwupunktowego

Nierówność Czebyszewa – przypomnienie

Dla zmiennej losowej o skończonej wartości oczekiwanej i wariancji:

$$\forall \epsilon > 0 \quad P(|X - EX| > \epsilon) \leq \frac{D^2(X)}{\epsilon^2}$$

Stosujemy twierdzenie do \bar{X}_n :

$$P(|\bar{X}_n - p| > \epsilon) \leq \frac{p(1-p)}{n\epsilon^2} \implies P(|\bar{X}_n - p| \leq \epsilon) \geq 1 - \frac{p(1-p)}{n\epsilon^2}$$

Szansa odchylenia się częstości o co najwyżej ϵ od prawdopodobieństwa sukcesu rośnie z n

Prawo wielkich liczb dla rozkładu dwupunktowego

Nierówność Czebyszewa – przypomnienie

Dla zmiennej losowej o skończonej wartości oczekiwanej i wariancji:

$$\forall \epsilon > 0 \quad P(|X - EX| > \epsilon) \leq \frac{D^2(X)}{\epsilon^2}$$

Stosujemy twierdzenie do \bar{X}_n :

$$P(|\bar{X}_n - p| > \epsilon) \leq \frac{p(1-p)}{n\epsilon^2} \implies P(|\bar{X}_n - p| \leq \epsilon) \geq 1 - \frac{p(1-p)}{n\epsilon^2}$$

Prawo wielkich liczb Bernoulliego

Dla dowolnego $\epsilon > 0$:


$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - p| \leq \epsilon) = 1$$

Zmienna losowa \bar{X}_n zbiega „według prawdopodobieństwa” do p .

Prawo wielkich liczb Bernoulliego ($p = \frac{1}{2}$)

$$\forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - p| \leq \epsilon) = 1$$


$$P(|\bar{X}_n - p| \leq \epsilon) = P(p - \epsilon \leq \bar{X}_n \leq p + \epsilon)$$



Prawo wielkich liczb Bernoulliego ($p = \frac{1}{2}$)

$$\forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - p| \leq \epsilon) = 1$$


$$P(|\bar{X}_n - p| \leq \epsilon) = P(p - \epsilon \leq \bar{X}_n \leq p + \epsilon)$$



Prawo wielkich liczb Bernoulliego ($p = \frac{1}{2}$)

$$\forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - p| \leq \epsilon) = 1$$


$$P(|\bar{X}_n - p| \leq \epsilon) = P(p - \epsilon \leq \bar{X}_n \leq p + \epsilon)$$



Prawo wielkich liczb Bernoulliego ($p = \frac{1}{2}$)

$$\forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - p| \leq \epsilon) = 1$$


$$P(|\bar{X}_n - p| \leq \epsilon) = P(p - \epsilon \leq \bar{X}_n \leq p + \epsilon)$$



Prawo wielkich liczb Bernoulliego ($p = \frac{1}{2}$)

$$\forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - p| \leq \epsilon) = 1$$

$$P(|\bar{X}_n - p| \leq \epsilon) = P(p - \epsilon \leq \bar{X}_n \leq p + \epsilon)$$



Ciąg niezależnych zmiennych losowych

X_1, \dots, X_n – niezależne zmienne losowe o tym samym rozkładzie, a więc tej samej wartości oczekiwanej $EX_i = \mu$ i wariancji $D^2(X_i) = \sigma^2$.

Definiujemy: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

Ciąg niezależnych zmiennych losowych

X_1, \dots, X_n – niezależne zmienne losowe o tym samym rozkładzie, a więc tej samej wartości oczekiwanej $EX_i = \mu$ i wariancji $D^2(X_i) = \sigma^2$.

Definiujemy: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

$$E\bar{X}_n =$$

Ciąg niezależnych zmiennych losowych

X_1, \dots, X_n – niezależne zmienne losowe o tym samym rozkładzie, a więc tej samej wartości oczekiwanej $EX_i = \mu$ i wariancji $D^2(X_i) = \sigma^2$.

Definiujemy: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

$$E\bar{X}_n = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \underbrace{EX_i}_{\mu} = \mu$$

Ciąg niezależnych zmiennych losowych

X_1, \dots, X_n – niezależne zmienne losowe o tym samym rozkładzie, a więc tej samej wartości oczekiwanej $EX_i = \mu$ i wariancji $D^2(X_i) = \sigma^2$.

Definiujemy: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

$$E\bar{X}_n = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \underbrace{EX_i}_{\mu} = \mu$$

$$D^2(\bar{X}_n) =$$

Ciąg niezależnych zmiennych losowych

X_1, \dots, X_n – niezależne zmienne losowe o tym samym rozkładzie, a więc tej samej wartości oczekiwanej $EX_i = \mu$ i wariancji $D^2(X_i) = \sigma^2$.

Definiujemy: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

$$E\bar{X}_n = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \underbrace{EX_i}_{\mu} = \mu$$

$$D^2(\bar{X}_n) = D^2\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \underbrace{D^2(X_i)}_{\sigma^2} = \frac{\sigma^2}{n}$$

Ciąg niezależnych zmiennych losowych

X_1, \dots, X_n – niezależne zmienne losowe o tym samym rozkładzie, a więc tej samej wartości oczekiwanej $EX_i = \mu$ i wariancji $D^2(X_i) = \sigma^2$.

Definiujemy: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

$$E\bar{X}_n = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \underbrace{EX_i}_{\mu} = \mu$$

$$D^2(\bar{X}_n) = D^2\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \underbrace{D^2(X_i)}_{\sigma^2} = \frac{\sigma^2}{n}$$

Stosujemy nierówność Czebyszewa:

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{D^2(\bar{X}_n)}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2}$$

Ciąg niezależnych zmiennych losowych

X_1, \dots, X_n – niezależne zmienne losowe o tym samym rozkładzie, a więc tej samej wartości oczekiwanej $EX_i = \mu$ i wariancji $D^2(X_i) = \sigma^2$.

Definiujemy: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

$$E\bar{X}_n = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \underbrace{EX_i}_{\mu} = \mu$$

$$D^2(\bar{X}_n) = D^2\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \underbrace{D^2(X_i)}_{\sigma^2} = \frac{\sigma^2}{n}$$

Stosujemy nierówność Czebyszewa:

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{D^2(\bar{X}_n)}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2} \xrightarrow{n \rightarrow \infty} 0$$

Prawo wielkich liczb

Słabe prawo wielkich liczb Chińczyna

Niech X_1, X_2, \dots będzie ciągiem niezależnych zmiennych losowych o tym samym rozkładzie, mających wartość oczekiwaną μ i wariancję $\sigma^2 < \infty$. Wtedy dla dowolnego $\epsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \leq \epsilon) = 1$$

Prawo wielkich liczb

Słabe prawo wielkich liczb Chińczyna

Niech X_1, X_2, \dots będzie ciągiem niezależnych zmiennych losowych o tym samym rozkładzie, mających wartość oczekiwaną μ i wariancję $\sigma^2 < \infty$. Wtedy dla dowolnego $\epsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \leq \epsilon) = 1$$

Prawo wielkich liczb Bernoulliego jest szczególnym przypadkiem tego twierdzenia, jeśli zmienne X_1, X_2, \dots mają rozkład dwupunktowy.

Zbieżność według prawdopodobieństwa

Niech $X_n = (X_1, X_2, \dots)$ będzie ciągiem zmiennych losowych.

Mówimy, że ciąg X_n dąży do zmiennej losowej X **według prawdopodobieństwa**, jeśli dla dowolnego $\epsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) = 0$$

Oznaczamy $X_n \xrightarrow{P} X$

Zbieżność według prawdopodobieństwa

Niech $X_n = (X_1, X_2, \dots)$ będzie ciągiem zmiennych losowych.

Mówimy, że ciąg X_n dąży do zmiennej losowej X **według prawdopodobieństwa**, jeśli dla dowolnego $\epsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) = 0$$

Oznaczamy $X_n \xrightarrow{P} X$

W szczególności, jeśli X ma rozkład jednopunktowy, tzn. $P(X = c) = 1$, zapisujemy $X_n \xrightarrow{P} c$.

Zbieżność według prawdopodobieństwa

Niech $X_n = (X_1, X_2, \dots)$ będzie ciągiem zmiennych losowych.

Mówimy, że ciąg X_n dąży do zmiennej losowej X **według prawdopodobieństwa**, jeśli dla dowolnego $\epsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) = 0$$

Oznaczamy $X_n \xrightarrow{P} X$

W szczególności, jeśli X ma rozkład jednopunktowy, tzn. $P(X = c) = 1$, zapisujemy $X_n \xrightarrow{P} c$.

Korzystając z powyższej równości możemy przepisać prawa wielkich liczb

Prawo wielkich liczb

Słabe prawo wielkich liczb Chińczyna

Niech X_1, X_2, \dots będzie ciągiem niezależnych zmiennych losowych o tym samym rozkładzie, mających wartość oczekiwaną μ i wariancję $\sigma^2 < \infty$.
Wtedy:

$$\overline{X}_n \xrightarrow{P} \mu$$

Prawo wielkich liczb

Słabe prawo wielkich liczb Czebyszewa

Niech X_1, X_2, \dots będzie ciągiem niezależnych zmiennych losowych z wartościami oczekiwanymi $EX_i = \mu_i$ i wariancjami $D^2(X_i) = \sigma_i^2$, wspólnie ograniczonymi przez σ^2 (tzn. $\sigma_i^2 \leq \sigma^2$ dla wszystkich i). Niech $\bar{\mu}_n = \frac{1}{n} \sum_{i=1}^n \mu_i$. Wtedy

$$\bar{X}_n - \bar{\mu}_n \xrightarrow{P} 0$$

Prawo wielkich liczb

Słabe prawo wielkich liczb Czebyszewa

Niech X_1, X_2, \dots będzie ciągiem niezależnych zmiennych losowych z wartościami oczekiwanymi $EX_i = \mu_i$ i wariancjami $D^2(X_i) = \sigma_i^2$, wspólnie ograniczonymi przez σ^2 (tzn. $\sigma_i^2 \leq \sigma^2$ dla wszystkich i). Niech $\bar{\mu}_n = \frac{1}{n} \sum_{i=1}^n \mu_i$. Wtedy

$$\bar{X}_n - \bar{\mu}_n \xrightarrow{P} 0$$

Zadanie 1

Udowodnij to twierdzenie

Zbieżność „z prawdopodobieństwem jeden”

Rozważmy wyrażenie:

$$\lim_{n \rightarrow \infty} X_n = X$$

Zbieżność „z prawdopodobieństwem jeden”

Rozważmy wyrażenie:

$$\lim_{n \rightarrow \infty} X_n = X$$

Ta równość dotyczy się **zmiennych losowych**,
powyższe wyrażenie jest więc **zdarzeniem losowym!**

Zbieżność „z prawdopodobieństwem jeden”

Rozważmy wyrażenie:

$$\forall \omega \in \Omega \quad \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$$

Zbieżność „z prawdopodobieństwem jeden”

Rozważmy wyrażenie:

$$\forall \omega \in \Omega \quad \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$$

To stwierdzenie nazywa się **zbieżnością „na pewno”**: zbieżność zachodzi dla **wszystkich** $\omega \in \Omega$.

Zwykle **zbyt silne**, ponieważ musi zajść dla ω , dla których $P(\{\omega\}) = 0$ (np. dla schematu Bernoulliego może się zdarzyć (z prawd. 0), że zaobserwujemy **samą porażkę**)

Zbieżność „z prawdopodobieństwem jeden”

Rozważmy wyrażenie:

$$\forall \omega \in \Omega \quad \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$$

To stwierdzenie nazywa się **zbieżnością „na pewno”**: zbieżność zachodzi dla **wszystkich** $\omega \in \Omega$.

Zwykle **zbyt silne**, ponieważ musi zajść dla ω , dla których $P(\{\omega\}) = 0$ (np. dla schematu Bernoulliego może się zdarzyć (z prawd. 0), że zaobserwujemy **samą porażkę**)

Mówimy, że ciąg X_n dąży do zmiennej losowej X **z prawdopodobieństwem jeden** („prawie na pewno”) jeśli:

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

Zapisujemy $X_n \xrightarrow{\text{pr. 1}} X$

Zbieżność według prawdopodobieństwa a zbieżność z prawdopodobieństwem jeden

$$\begin{aligned} P\left(\lim_{n \rightarrow \infty} X_n = X\right) &= 1 && \left(X_n \xrightarrow{\text{pr. } 1} X\right) \\ \forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) &= 0 && \left(X_n \xrightarrow{P} X\right) \end{aligned}$$

Zbieżność według prawdopodobieństwa a zbieżność z prawdopodobieństwem jeden

$$\begin{aligned} P\left(\lim_{n \rightarrow \infty} X_n = X\right) &= 1 && \left(X_n \xrightarrow{\text{pr. } 1} X\right) \\ \forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) &= 0 && \left(X_n \xrightarrow{P} X\right) \end{aligned}$$

Zbieżność z prawdopodobieństwem jeden implikuje zbieżność według prawdopodobieństwa:

$$X_n \xrightarrow{\text{pr. } 1} X \quad \implies \quad X_n \xrightarrow{P} X$$

Zbieżność według prawdopodobieństwa a zbieżność z prawdopodobieństwem jeden

$$\begin{aligned} P\left(\lim_{n \rightarrow \infty} X_n = X\right) &= 1 && \left(X_n \xrightarrow{\text{pr. } 1} X\right) \\ \forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) &= 0 && \left(X_n \xrightarrow{P} X\right) \end{aligned}$$

Zbieżność z prawdopodobieństwem jeden implikuje zbieżność według prawdopodobieństwa:

$$X_n \xrightarrow{\text{pr. } 1} X \quad \implies \quad X_n \xrightarrow{P} X$$

Zadanie 2

Udowodnij tę implikację

Zbieżność według prawdopodobieństwa a zbieżność z prawdopodobieństwem jeden

$$\begin{aligned} P\left(\lim_{n \rightarrow \infty} X_n = X\right) &= 1 && \left(X_n \xrightarrow{\text{pr. } 1} X\right) \\ \forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) &= 0 && \left(X_n \xrightarrow{P} X\right) \end{aligned}$$

Zbieżność z prawdopodobieństwem jeden implikuje zbieżność według prawdopodobieństwa:

$$X_n \xrightarrow{\text{pr. } 1} X \quad \implies \quad X_n \xrightarrow{P} X$$

Zadanie 2


Udowodnij tę implikację

Pokażemy **kontrprzykład**, że implikacja w drugą stronę **nie zachodzi**

Kontrprzykład: losowanie punktów z odcinka

$\Omega = [0, 1]$, P – rozkład jednostajny na $[0, 1]$.


Badamy zbieżność ciągu X_1, X_2, \dots do zmiennej $X(\omega) = 0 \quad \forall \omega \in [0, 1]$



Kontrprzykład: losowanie punktów z odcinka

$\Omega = [0, 1]$, P – rozkład jednostajny na $[0, 1]$.


Badamy zbieżność ciągu X_1, X_2, \dots do zmiennej $X(\omega) = 0 \quad \forall \omega \in [0, 1]$



Kontrprzykład: losowanie punktów z odcinka

$\Omega = [0, 1]$, P – rozkład jednostajny na $[0, 1]$.


Badamy zbieżność ciągu X_1, X_2, \dots do zmiennej $X(\omega) = 0 \quad \forall \omega \in [0, 1]$



Kontrprzykład: losowanie punktów z odcinka

$\Omega = [0, 1]$, P – rozkład jednostajny na $[0, 1]$.


Badamy zbieżność ciągu X_1, X_2, \dots do zmiennej $X(\omega) = 0 \quad \forall \omega \in [0, 1]$



Kontrprzykład: losowanie punktów z odcinka

$\Omega = [0, 1]$, P – rozkład jednostajny na $[0, 1]$.


Badamy zbieżność ciągu X_1, X_2, \dots do zmiennej $X(\omega) = 0 \quad \forall \omega \in [0, 1]$



Kontrprzykład: losowanie punktów z odcinka

$\Omega = [0, 1]$, P – rozkład jednostajny na $[0, 1]$.


Badamy zbieżność ciągu X_1, X_2, \dots do zmiennej $X(\omega) = 0 \quad \forall \omega \in [0, 1]$



Kontrprzykład: losowanie punktów z odcinka

$\Omega = [0, 1]$, P – rozkład jednostajny na $[0, 1]$.


Badamy zbieżność ciągu X_1, X_2, \dots do zmiennej $X(\omega) = 0 \quad \forall \omega \in [0, 1]$



Kontrprzykład: losowanie punktów z odcinka

$\Omega = [0, 1]$, P – rozkład jednostajny na $[0, 1]$.


Badamy zbieżność ciągu X_1, X_2, \dots do zmiennej $X(\omega) = 0 \quad \forall \omega \in [0, 1]$



Kontrprzykład: losowanie punktów z odcinka

$\Omega = [0, 1]$, P – rozkład jednostajny na $[0, 1]$.


Badamy zbieżność ciągu X_1, X_2, \dots do zmiennej $X(\omega) = 0 \quad \forall \omega \in [0, 1]$



Kontrprzykład: losowanie punktów z odcinka

$\Omega = [0, 1]$, P – rozkład jednostajny na $[0, 1]$.


Badamy zbieżność ciągu X_1, X_2, \dots do zmiennej $X(\omega) = 0 \quad \forall \omega \in [0, 1]$



Kontrprzykład: losowanie punktów z odcinka

Ponieważ $X_n \in \{0, 1\}$ i $X \equiv 0$, mamy:


$$\forall \epsilon \in (0, 1) \quad |X_n - X| > \epsilon \iff X_n = 1$$



Kontrprzykład: losowanie punktów z odcinka

Ponieważ $X_n \in \{0, 1\}$ i $X \equiv 0$, mamy:


$$\forall \epsilon \in (0, 1) \quad |X_n - X| > \epsilon \iff X_n = 1$$



Kontrprzykład: losowanie punktów z odcinka

Ponieważ $X_n \in \{0, 1\}$ i $X \equiv 0$, mamy:


$$\forall \epsilon \in (0, 1) \quad |X_n - X| > \epsilon \iff X_n = 1$$



Kontrprzykład: losowanie punktów z odcinka

Ponieważ $X_n \in \{0, 1\}$ i $X \equiv 0$, mamy:


$$\forall \epsilon \in (0, 1) \quad |X_n - X| > \epsilon \iff X_n = 1$$



Kontrprzykład: losowanie punktów z odcinka

Ponieważ $X_n \in \{0, 1\}$ i $X \equiv 0$, mamy:


$$\forall \epsilon \in (0, 1) \quad |X_n - X| > \epsilon \iff X_n = 1$$



Kontrprzykład: losowanie punktów z odcinka

Ponieważ $X_n \in \{0, 1\}$ i $X \equiv 0$, mamy:


$$\forall \epsilon \in (0, 1) \quad |X_n - X| > \epsilon \iff X_n = 1$$



Kontrprzykład: losowanie punktów z odcinka

Ponieważ $X_n \in \{0, 1\}$ i $X \equiv 0$, mamy:


$$\forall \epsilon \in (0, 1) \quad |X_n - X| > \epsilon \iff X_n = 1$$



Kontrprzykład: losowanie punktów z odcinka

Ponieważ $X_n \in \{0, 1\}$ i $X \equiv 0$, mamy:


$$\forall \epsilon \in (0, 1) \quad |X_n - X| > \epsilon \iff X_n = 1$$



Kontrprzykład: losowanie punktów z odcinka

Ponieważ $X_n \in \{0, 1\}$ i $X \equiv 0$, mamy:


$$\forall \epsilon \in (0, 1) \quad |X_n - X| > \epsilon \iff X_n = 1$$



Kontrprzykład: losowanie punktów z odcinka


Ponieważ $X_n \in \{0, 1\}$ i $X \equiv 0$, mamy:

$$\forall \epsilon \in (0, 1) \quad |X_n - X| > \epsilon \iff X_n = 1$$



Kontrprzykład: losowanie punktów z odcinka


Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !


$$X_n(\omega_0) =$$



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !


$$X_n(\omega_0) = 1,$$



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !


$$X_n(\omega_0) = 1, 1,$$



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !


$$X_n(\omega_0) = 1, 1, 0,$$



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !


$$X_n(\omega_0) = 1, 1, 0, 1,$$



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !


$$X_n(\omega_0) = 1, 1, 0, 1, 0,$$



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !


$$X_n(\omega_0) = 1, 1, 0, 1, 0, 0,$$



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !


$$X_n(\omega_0) = 1, 1, 0, 1, 0, 0, 0,$$



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !


$$X_n(\omega_0) = 1, 1, 0, 1, 0, 0, 0, 1, \dots$$



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !

$$X_n(\omega_0) = 1, 1, 0, 1, 0, 0, 0, 1, \dots$$



Kontrprzykład: losowanie punktów z odcinka

Ale: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ nie zachodzi dla żadnego ω !

$$X_n(\omega_0) = 1, 1, 0, 1, 0, 0, 0, 1, \dots$$

$X(\omega)$
1

Ten ciąg nie ma granicy!

Wniosek: zachodzi $X_n \xrightarrow{P} X$, ale

$$P(\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)) = 0 !$$



Mocne prawo wielkich liczb

Pokazaliśmy, że:

$$X_n \xrightarrow{P} X \quad \Rightarrow \quad X_n \xrightarrow{\text{z pr. 1}} X$$

Mocne prawo wielkich liczb

Pokazaliśmy, że:

$$X_n \xrightarrow{P} X \quad \Rightarrow \quad X_n \xrightarrow{\text{z pr. 1}} X$$

Mimo to prawa wielkich liczb można **wzmocnić** do warunku $X_n \xrightarrow{\text{z pr. 1}} X$

Mocne prawo wielkich liczb

Pokazaliśmy, że:

$$X_n \xrightarrow{P} X \quad \not\Rightarrow \quad X_n \xrightarrow{\text{z pr. 1}} X$$

Mimo to prawa wielkich liczb można **wzmocnić** do warunku $X_n \xrightarrow{\text{z pr. 1}} X$

Silne prawo wielkich liczb Chińczyna

Niech X_1, X_2, \dots będzie ciągiem niezależnych zmiennych losowych o tym samym rozkładzie, z wartością oczekiwaną μ i wariancją $\sigma^2 < \infty$. Wtedy:

$$\bar{X}_n \xrightarrow{\text{z pr. 1}} \mu$$

Silne prawo wielkich liczb Czebyszewa

Niech X_1, X_2, \dots będzie ciągiem niezależnych zmiennych losowych z $EX_i = \mu_i$ i wariancjami $D^2(X_i) = \sigma_i^2$, wspólnie ograniczonymi przez σ^2 . Niech $\bar{\mu}_n = \frac{1}{n} \sum_{i=1}^n \mu_i$. Wtedy:

$$\bar{X}_n - \bar{\mu}_n \xrightarrow{\text{z pr. 1}} 0$$

Twierdzenia pozostawiamy bez dowodu.

Częstościowa interpretacja prawdopodobieństwa

Dotyczy **powtarzalnych** doświadczeń losowych.

Powtórzmy N razy doświadczenie losowe.

Dla dowolnego zdarzenia A , niech N_A oznacza liczbę doświadczeń w których A **zaszło**.

Prawdopodobieństwo zdarzenia A jest graniczną wartością **częstości**:

$$P(A) = \lim_{N \rightarrow \infty} \frac{N_A}{N}.$$

Częstościowa interpretacja prawdopodobieństwa

Dla dowolnego zdarzenia A , rozważmy zmienne losowe X_1, X_2, \dots, X_N dotyczące poszczególnych doświadczeń, określone jako:

$$X_i(\omega) = \begin{cases} 1 & \text{jeśli } \omega \in A \\ 0 & \text{jeśli } \omega \notin A \end{cases}$$

Częstościowa interpretacja prawdopodobieństwa

Dla dowolnego zdarzenia A , rozważmy zmienne losowe X_1, X_2, \dots, X_N dotyczące poszczególnych doświadczeń, określone jako:

$$X_i(\omega) = \begin{cases} 1 & \text{jeśli } \omega \in A \\ 0 & \text{jeśli } \omega \notin A \end{cases}$$

Zmienne te są niezależne i mają rozkład **dwupunktowy** $B(p)$ z parametrem $p = P(X_i = 1) = P(A)$.

Częstościowa interpretacja prawdopodobieństwa

Dla dowolnego zdarzenia A , rozważmy zmienne losowe X_1, X_2, \dots, X_N dotyczące poszczególnych doświadczeń, określone jako:

$$X_i(\omega) = \begin{cases} 1 & \text{jeśli } \omega \in A \\ 0 & \text{jeśli } \omega \notin A \end{cases}$$





Zmienne te są niezależne i mają rozkład **dwupunktowy** $B(p)$ z parametrem $p = P(X_i = 1) = P(A)$.

Wtedy z mocnego prawa wielkich liczb:

$$\frac{N_A}{N} = \bar{X}_N \xrightarrow{\text{pr. 1}} P(A)$$

Uzasadnia to częstościową interpretację prawdopodobieństwa.

Schemat Bernoulliego ($p = \frac{1}{2}$): rozkład zmiennej $\bar{X}_n = \frac{S_n}{n}$



Standaryzacja zmiennej losowej

Zmienną X , dla której $EX = 0$ i $D^2(X) = 1$ nazywa się **zmienną losową standaryzowaną**

Standaryzacja zmiennej losowej

Zmienną X , dla której $EX = 0$ i $D^2(X) = 1$ nazywa się **zmienną losową standaryzowaną**

Standaryzacja zmiennej losowej:

Dla dowolnej zmiennej X , zmienna:

$$U = \frac{X - EX}{D(X)} \quad \text{jest zmienną standaryzowaną}$$

Zadanie 3

Udowodnij to stwierdzenie korzystając ze znanych własności $E(aX + b) = aEX + b$ oraz $D^2(aX + b) = a^2 D^2(X)$

Schemat Bernoulliego $B(n, p)$

$$S_n = \sum_{i=1}^n X_i, \quad ES_n = np, \quad D^2(S_n) = np(1-p)$$

$$\bar{X}_n = \frac{S_n}{n}, \quad E\bar{X}_n = p, \quad D^2(\bar{X}_n) = \frac{p(1-p)}{n}$$

Schemat Bernoulliego $B(n, p)$

$$\begin{aligned} S_n &= \sum_{i=1}^n X_i, & ES_n &= np, & D^2(S_n) &= np(1-p) \\ \bar{X}_n &= \frac{S_n}{n}, & E\bar{X}_n &= p, & D^2(\bar{X}_n) &= \frac{p(1-p)}{n} \end{aligned}$$

Jak zachowuje się ciąg S_n (lub \bar{X}_n) po **standaryzacji**?

$$U_n = \frac{S_n - ES_n}{D(S_n)} = \frac{S_n - np}{\sqrt{np(1-p)}} = \frac{\bar{X}_n - E\bar{X}_n}{D(\bar{X}_n)} = \frac{\bar{X}_n - p}{\sqrt{p(1-p)}} \sqrt{n}$$

Schemat Bernoulliego $B(n, p)$

$$\begin{aligned} S_n &= \sum_{i=1}^n X_i, & ES_n &= np, & D^2(S_n) &= np(1-p) \\ \bar{X}_n &= \frac{S_n}{n}, & E\bar{X}_n &= p, & D^2(\bar{X}_n) &= \frac{p(1-p)}{n} \end{aligned}$$

Jak zachowuje się ciąg S_n (lub \bar{X}_n) po **standaryzacji**?

$$U_n = \frac{S_n - ES_n}{D(S_n)} = \frac{S_n - np}{\sqrt{np(1-p)}} = \frac{\bar{X}_n - E\bar{X}_n}{D(\bar{X}_n)} = \frac{\bar{X}_n - p}{\sqrt{p(1-p)}} \sqrt{n}$$

Interpretacja: patrzymy na S_n (lub \bar{X}_n) dobierając zawsze skalę i przesunięcie początku układu współrzędnych tak, aby wartość oczekiwana znajdowała się w punkcie 0, a odchylenie standardowe było jednostkowe.

Schemat Bernoulliego $B(n, p)$

$$\begin{aligned} S_n &= \sum_{i=1}^n X_i, & ES_n &= np, & D^2(S_n) &= np(1-p) \\ \bar{X}_n &= \frac{S_n}{n}, & E\bar{X}_n &= p, & D^2(\bar{X}_n) &= \frac{p(1-p)}{n} \end{aligned}$$


Jak zachowuje się ciąg S_n (lub \bar{X}_n) po **standaryzacji**?

$$U_n = \frac{S_n - ES_n}{D(S_n)} = \frac{S_n - np}{\sqrt{np(1-p)}} = \frac{\bar{X}_n - E\bar{X}_n}{D(\bar{X}_n)} = \frac{\bar{X}_n - p}{\sqrt{p(1-p)}} \sqrt{n}$$


Interpretacja: patrzymy na S_n (lub \bar{X}_n) dobierając zawsze skalę i przesunięcie początku układu współrzędnych tak, aby wartość oczekiwana znajdowała się w punkcie 0, a odchylenie standardowe było jednostkowe.

Ciąg U_n nie zbiega teraz do liczby, ponieważ ma stale jednostkowe odchylenie standardowe!


Rozkład zmiennej U_n ($p = \frac{1}{2}$)




Rozkład zmiennej U_n ($p = \frac{1}{2}$)




Rozkład zmiennej U_n ($p = \frac{1}{2}$)




Rozkład zmiennej U_n ($p = \frac{1}{2}$)



Rozkład zmiennej U_n ($p = \frac{1}{2}$)



Rozkład zmiennej U_n ($p = \frac{1}{2}$)



Twierdzenie Moivre'a-Laplace'a

Rozważmy ciąg niezależnych zmiennych losowych X_1, X_2, X_3, \dots , gdzie $X_n \sim B(p)$ dla wszystkich n

$$S_n = \sum_{i=1}^n X_i \sim B(n, p), \quad U_n = \frac{S_n - np}{\sqrt{np(1-p)}}$$

Dystrybucja zmiennej U_n zbiega do dystrybucji standardowego rozkładu normalnego:

$$\forall x \quad \lim_{n \rightarrow \infty} F_{U_n}(x) = \Phi(x)$$

Wnioski z twierdzenia Moivre'a-Laplace'a

- Dla dużych n , rozkład zmiennej U_n można przybliżyć rozkładem normalnym $N(0, 1)$:

$$U_n = \frac{S_n - np}{\sqrt{np(1-p)}} \simeq X, \quad \text{gdzie } X \sim N(0, 1)$$

Wnioski z twierdzenia Moivre'a-Laplace'a

- Dla dużych n , rozkład zmiennej U_n można przybliżyć rozkładem normalnym $N(0, 1)$:

$$U_n = \frac{S_n - np}{\sqrt{np(1-p)}} \simeq X, \quad \text{gdzie } X \sim N(0, 1)$$

- Równoważnie, można przybliżyć rozkład zmiennej $S_n \sim B(n, p)$:

$$S_n \simeq \sqrt{np(1-p)}X + np \sim N(np, np(1-p))$$

Wnioski z twierdzenia Moivre'a-Laplace'a

- Dla dużych n , rozkład zmiennej U_n można przybliżyć rozkładem normalnym $N(0, 1)$:

$$U_n = \frac{S_n - np}{\sqrt{np(1-p)}} \simeq X, \quad \text{gdzie } X \sim N(0, 1)$$

- Równoważnie, można przybliżyć rozkład zmiennej $S_n \sim B(n, p)$:

$$S_n \simeq \sqrt{np(1-p)}X + np \sim N(np, np(1-p))$$

- **Wniosek:** dla dużych n , rozkład dwumianowy $B(n, p)$ można przybliżać rozkładem normalnym $N(np, np(1-p))$

Wnioski z twierdzenia Moivre'a-Laplace'a

- Dla dużych n , rozkład zmiennej U_n można przybliżyć rozkładem normalnym $N(0, 1)$:

$$U_n = \frac{S_n - np}{\sqrt{np(1-p)}} \simeq X, \quad \text{gdzie } X \sim N(0, 1)$$

- Równoważnie, można przybliżyć rozkład zmiennej $S_n \sim B(n, p)$:

$$S_n \simeq \sqrt{np(1-p)}X + np \sim N(np, np(1-p))$$

- **Wniosek:** dla dużych n , rozkład dwumianowy $B(n, p)$ można przybliżać rozkładem normalnym $N(np, np(1-p))$
- Przybliżenie to można stosować już dla niewielkiego n : warunek stosowalności określa się zwykle na: $np \geq 5$ i $n(1-p) \geq 5$.

Przykład

Oszacuj prawdopodobieństwo, że liczba sukcesów S_n w rozkładzie dwumianowym $B(n = 30, p = \frac{1}{3})$ znajdzie się w zakresie $\{9, 10, 11, 12\}$.

Przykład

Oszacuj prawdopodobieństwo, że liczba sukcesów S_n w rozkładzie dwumianowym $B(n = 30, p = \frac{1}{3})$ znajdzie się w zakresie $\{9, 10, 11, 12\}$.

Odpowiedź dokładna:

$$P(9 \leq S_n \leq 12) = \sum_{k=9}^{12} \binom{30}{k} \left(\frac{1}{3}\right)^k \left(\frac{2}{3}\right)^{30-k} \simeq 0.548$$

Przykład

Oszacuj prawdopodobieństwo, że liczba sukcesów S_n w rozkładzie dwumianowym $B(n = 30, p = \frac{1}{3})$ znajdzie się w zakresie $\{9, 10, 11, 12\}$.

Odpowiedź przybliżona:

Warunki przybliżenia spełnione: $np = 10 \geq 5$, $n(1 - p) = 20 \geq 5$

$$P(a \leq S_n \leq b) = P\left(\frac{a - np}{\sqrt{np(1 - p)}} \leq \frac{S_n - np}{\sqrt{np(1 - p)}} \leq \frac{b - np}{\sqrt{np(1 - p)}}\right)$$

Przykład

Oszacuj prawdopodobieństwo, że liczba sukcesów S_n w rozkładzie dwumianowym $B(n = 30, p = \frac{1}{3})$ znajdzie się w zakresie $\{9, 10, 11, 12\}$.

Odpowiedź przybliżona:

Warunki przybliżenia spełnione: $np = 10 \geq 5$, $n(1 - p) = 20 \geq 5$

$$P(a \leq S_n \leq b) = P\left(\frac{a - np}{\sqrt{np(1 - p)}} \leq \underbrace{\frac{S_n - np}{\sqrt{np(1 - p)}}}_{U_n \simeq X \sim N(0,1)} \leq \frac{b - np}{\sqrt{np(1 - p)}}\right)$$

Przykład

Oszacuj prawdopodobieństwo, że liczba sukcesów S_n w rozkładzie dwumianowym $B(n = 30, p = \frac{1}{3})$ znajdzie się w zakresie $\{9, 10, 11, 12\}$.

Odpowiedź przybliżona:

Warunki przybliżenia spełnione: $np = 10 \geq 5$, $n(1 - p) = 20 \geq 5$

$$\begin{aligned} P(a \leq S_n \leq b) &= P\left(\frac{a - np}{\sqrt{np(1 - p)}} \leq \underbrace{\frac{S_n - np}{\sqrt{np(1 - p)}}}_{U_n \simeq X \sim N(0,1)} \leq \frac{b - np}{\sqrt{np(1 - p)}}\right) \\ &\simeq P\left(\frac{a - np}{\sqrt{np(1 - p)}} \leq X \leq \frac{b - np}{\sqrt{np(1 - p)}}\right) \quad (X \sim N(0,1)) \end{aligned}$$

Przykład

Oszacuj prawdopodobieństwo, że liczba sukcesów S_n w rozkładzie dwumianowym $B(n = 30, p = \frac{1}{3})$ znajdzie się w zakresie $\{9, 10, 11, 12\}$.

Odpowiedź przybliżona:

Warunki przybliżenia spełnione: $np = 10 \geq 5$, $n(1 - p) = 20 \geq 5$

$$\begin{aligned}P(a \leq S_n \leq b) &= P\left(\frac{a - np}{\sqrt{np(1 - p)}} \leq \underbrace{\frac{S_n - np}{\sqrt{np(1 - p)}}}_{U_n \simeq X \sim N(0,1)} \leq \frac{b - np}{\sqrt{np(1 - p)}}\right) \\&\simeq P\left(\frac{a - np}{\sqrt{np(1 - p)}} \leq X \leq \frac{b - np}{\sqrt{np(1 - p)}}\right) \quad (X \sim N(0,1)) \\&= \Phi\left(\frac{b - np}{\sqrt{np(1 - p)}}\right) - \Phi\left(\frac{a - np}{\sqrt{np(1 - p)}}\right)\end{aligned}$$

Przykład

Oszacuj prawdopodobieństwo, że liczba sukcesów S_n w rozkładzie dwumianowym $B(n = 30, p = \frac{1}{3})$ znajdzie się w zakresie $\{9, 10, 11, 12\}$.

Odpowiedź przybliżona:

Warunki przybliżenia spełnione: $np = 10 \geq 5$, $n(1 - p) = 20 \geq 5$

$$\begin{aligned} P(a \leq S_n \leq b) &= P\left(\frac{a - np}{\sqrt{np(1 - p)}} \leq \underbrace{\frac{S_n - np}{\sqrt{np(1 - p)}}}_{U_n \simeq X \sim N(0,1)} \leq \frac{b - np}{\sqrt{np(1 - p)}}\right) \\ &\simeq P\left(\frac{a - np}{\sqrt{np(1 - p)}} \leq X \leq \frac{b - np}{\sqrt{np(1 - p)}}\right) \quad (X \sim N(0,1)) \\ &= \Phi\left(\frac{b - np}{\sqrt{np(1 - p)}}\right) - \Phi\left(\frac{a - np}{\sqrt{np(1 - p)}}\right) \end{aligned}$$

Aby zwiększyć dokładność, bierzemy $b = 12.5$, $a = 8.5$:

$$P(8.5 \leq S_n \leq 12.5) \simeq \Phi(0.968) - \Phi(-0.581) \simeq 0.553$$

(odpowiedź dokładna: 0.548)

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$S_n \sim B(n, p), \quad P(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

Pokażemy, że dla dużych n , S_n można przybliżyć zmienną o rozkładzie normalnym $X \sim N(np, np(1-p))$:

$$P(S_n = k) \simeq P(X = k) = \frac{1}{\sqrt{2\pi np(1-p)}} e^{-\frac{(k-np)^2}{2np(1-p)}}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$S_n \sim B(n, p), \quad P(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

Pokażemy, że dla dużych n , S_n można przybliżyć zmienną o rozkładzie normalnym $X \sim N(np, np(1-p))$:

$$P(S_n = k) \simeq P(X = k) = \frac{1}{\sqrt{2\pi np(1-p)}} e^{-\frac{(k-np)^2}{2np(1-p)}}$$

Główne narzędzie: wzór Stirlinga

$$n! \simeq \left(\frac{n}{e}\right)^n \sqrt{2\pi n}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

Wzór Stirlinga: $n! \simeq \left(\frac{n}{e}\right)^n \sqrt{2\pi n}$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

Wzór Stirlinga: $n! \simeq \left(\frac{n}{e}\right)^n \sqrt{2\pi n}$

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} \simeq \sqrt{\frac{2\pi n}{(2\pi k)(2\pi(n-k))}} \frac{n^n e^{-n}}{k^k e^{-k} (n-k)^{n-k} e^{-(n-k)}}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

Wzór Stirlinga: $n! \simeq \left(\frac{n}{e}\right)^n \sqrt{2\pi n}$

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} \simeq \sqrt{\frac{2\pi n}{(2\pi k)(2\pi(n-k))}} \frac{n^n e^{-n}}{k^k e^{-k} (n-k)^{n-k} e^{-(n-k)}}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

Wzór Stirlinga: $n! \simeq \left(\frac{n}{e}\right)^n \sqrt{2\pi n}$

$$\begin{aligned}\binom{n}{k} &= \frac{n!}{k!(n-k)!} \simeq \sqrt{\frac{2\pi n}{(2\pi k)(2\pi(n-k))}} \frac{n^n e^{-n}}{k^k e^{-k} (n-k)^{n-k} e^{-(n-k)}} \\ &= \sqrt{\frac{n}{2\pi k(n-k)}} \frac{n^k n^{n-k}}{k^k (n-k)^{n-k}}\end{aligned}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$\text{Wzór Stirlinga: } n! \simeq \left(\frac{n}{e}\right)^n \sqrt{2\pi n}$$

$$\begin{aligned}\binom{n}{k} &= \frac{n!}{k!(n-k)!} \simeq \sqrt{\frac{2\pi n}{(2\pi k)(2\pi(n-k))}} \frac{n^n e^{-n}}{k^k e^{-k} (n-k)^{n-k} e^{-(n-k)}} \\ &= \sqrt{\frac{n}{2\pi k(n-k)}} \frac{n^k n^{n-k}}{k^k (n-k)^{n-k}}\end{aligned}$$

Stąd:

$$P(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k} \simeq \underbrace{\sqrt{\frac{n}{2\pi k(n-k)}}}_A \underbrace{\frac{(np)^k ((1-p)n)^{n-k}}{k^k (n-k)^{n-k}}}_B$$

Oszacujemy osobno wyrazy A i B

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$A = \sqrt{\frac{n}{2\pi k(n-k)}} = \sqrt{\frac{1}{2\pi n \frac{k}{n} \left(1 - \frac{k}{n}\right)}}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$A = \sqrt{\frac{n}{2\pi k(n-k)}} = \sqrt{\frac{1}{2\pi n \frac{k}{n} \left(1 - \frac{k}{n}\right)}}$$

Z prawa wielkich liczb, $\frac{S_n}{n} \xrightarrow{\text{pr. 1}} p$, stąd dla dużych n przybliżamy $\frac{k}{n}$ przez p , otrzymując:

$$A \simeq \frac{1}{\sqrt{2\pi np(1-p)}}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$B = \frac{(np)^k ((1-p)n)^{n-k}}{k^k (n-k)^{n-k}} = \left(\frac{k}{np}\right)^{-k} \left(\frac{n-k}{n(1-p)}\right)^{n-k}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$B = \frac{(np)^k ((1-p)n)^{n-k}}{k^k (n-k)^{n-k}} = \left(\frac{k}{np}\right)^{-k} \left(\frac{n-k}{n(1-p)}\right)^{n-k}$$

Zdefiniujemy sobie $x_k = \frac{k}{n}$ i przepiszymy B :

$$B = \left(\frac{x_k}{p}\right)^{-nx_k} \left(\frac{1-x_k}{1-p}\right)^{-n(1-x_k)}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$B = \frac{(np)^k ((1-p)n)^{n-k}}{k^k (n-k)^{n-k}} = \left(\frac{k}{np}\right)^{-k} \left(\frac{n-k}{n(1-p)}\right)^{n-k}$$

Zdefiniujemy sobie $x_k = \frac{k}{n}$ i przepiszmy B :

$$B = \left(\frac{x_k}{p}\right)^{-nx_k} \left(\frac{1-x_k}{1-p}\right)^{-n(1-x_k)}$$

Bierzemy logarytm B :

$$\ln B = -n \underbrace{\left(x_k \ln \frac{x_k}{p} + (1-x_k) \ln \frac{1-x_k}{1-p} \right)}_{f(x_k)}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$B = \frac{(np)^k ((1-p)n)^{n-k}}{k^k (n-k)^{n-k}} = \left(\frac{k}{np}\right)^{-k} \left(\frac{n-k}{n(1-p)}\right)^{n-k}$$

Zdefiniujemy sobie $x_k = \frac{k}{n}$ i przepiszmy B :

$$B = \left(\frac{x_k}{p}\right)^{-nx_k} \left(\frac{1-x_k}{1-p}\right)^{-n(1-x_k)}$$

Bierzemy logarytm B :

$$\ln B = -n \underbrace{\left(x_k \ln \frac{x_k}{p} + (1-x_k) \ln \frac{1-x_k}{1-p} \right)}_{f(x_k)}$$

Rozwijamy funkcję $f(x_k)$ w punkcie $x_k = p$ wykorzystujemy przybliżenia Taylora do drugiego rzędu:

$$f(x_k) \simeq f(p) + f'(p)(x_k - p) + \frac{1}{2}f''(p)(x_k - p)^2$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$f(x_k) = x_k(\ln x_k - \ln p) + (1 - x_k)(\ln(1 - x_k) - \ln(1 - p))$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$f(x_k) = x_k(\ln x_k - \ln p) + (1 - x_k)(\ln(1 - x_k) - \ln(1 - p))$$

$$f'(x_k) = \log x_k - \log p - \log(1 - x_k) + \log(1 - p)$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$f(x_k) = x_k(\ln x_k - \ln p) + (1 - x_k)(\ln(1 - x_k) - \ln(1 - p))$$

$$f'(x_k) = \log x_k - \log p - \log(1 - x_k) + \log(1 - p)$$

$$f''(x_k) = \frac{1}{x_k} + \frac{1}{1 - x_k}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$f(x_k) = x_k(\ln x_k - \ln p) + (1 - x_k)(\ln(1 - x_k) - \ln(1 - p))$$

$$f'(x_k) = \log x_k - \log p - \log(1 - x_k) + \log(1 - p)$$

$$f''(x_k) = \frac{1}{x_k} + \frac{1}{1 - x_k}$$

$$f(p) = p(\ln p - \ln p) + (1 - p)(\ln(1 - p) - \ln(1 - p)) = 0$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$f(x_k) = x_k(\ln x_k - \ln p) + (1 - x_k)(\ln(1 - x_k) - \ln(1 - p))$$

$$f'(x_k) = \log x_k - \log p - \log(1 - x_k) + \log(1 - p)$$

$$f''(x_k) = \frac{1}{x_k} + \frac{1}{1 - x_k}$$

$$f(p) = p(\ln p - \ln p) + (1 - p)(\ln(1 - p) - \ln(1 - p)) = 0$$

$$f'(p) = \log p - \log p - \log(1 - p) + \log(1 - p) = 0$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$f(x_k) = x_k(\ln x_k - \ln p) + (1 - x_k)(\ln(1 - x_k) - \ln(1 - p))$$

$$f'(x_k) = \log x_k - \log p - \log(1 - x_k) + \log(1 - p)$$

$$f''(x_k) = \frac{1}{x_k} + \frac{1}{1 - x_k}$$

$$f(p) = p(\ln p - \ln p) + (1 - p)(\ln(1 - p) - \ln(1 - p)) = 0$$

$$f'(p) = \log p - \log p - \log(1 - p) + \log(1 - p) = 0$$

$$f''(p) = \frac{1}{p} + \frac{1}{1 - p} = \frac{p + (1 - p)}{p(1 - p)} = \frac{1}{p(1 - p)}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

$$f(x_k) = x_k(\ln x_k - \ln p) + (1 - x_k)(\ln(1 - x_k) - \ln(1 - p))$$

$$f'(x_k) = \log x_k - \log p - \log(1 - x_k) + \log(1 - p)$$

$$f''(x_k) = \frac{1}{x_k} + \frac{1}{1 - x_k}$$

$$f(p) = p(\ln p - \ln p) + (1 - p)(\ln(1 - p) - \ln(1 - p)) = 0$$

$$f'(p) = \log p - \log p - \log(1 - p) + \log(1 - p) = 0$$

$$f''(p) = \frac{1}{p} + \frac{1}{1 - p} = \frac{p + (1 - p)}{p(1 - p)} = \frac{1}{p(1 - p)}$$

Stąd:

$$f(x_k) \simeq \underbrace{f(p)}_0 + \underbrace{f'(p)}_0(x_k - p) + \frac{1}{2}f''(p)(x_k - p)^2 = \frac{(x_k - p)^2}{2p(1 - p)}$$

Dowód twierdzenia Moivre'a-Laplace'a (nieformalnie)

Pokazaliśmy, że:

$$\ln B = -nf(x_k) \simeq -\frac{n(x_k - p)^2}{2p(1-p)}$$

Używając $x_k = \frac{k}{n}$ lub $k = x_k n$:

$$\ln B = -\frac{(nx_k - np)^2}{2np(1-p)} = -\frac{(k - np)^2}{2np(1-p)} \implies B = e^{-\frac{(k - np)^2}{2np(1-p)}}$$

pamiętając, że $P(S_k = k) = A \cdot B$ i wykorzystując szacowanie A otrzymujemy:

$$P(S_k = k) \simeq \frac{1}{\sqrt{2\pi np(1-p)}} e^{-\frac{(k - np)^2}{2np(1-p)}},$$

co należało pokazać.

Centralne Twierdzenie Graniczne

$X_1, X_2, X_3 \dots$ – ciąg niezależnych zmiennych losowych o tym samym rozkładzie, $EX_i = \mu$, $D^2(X_i) = \sigma^2$.

Centralne Twierdzenie Graniczne

$X_1, X_2, X_3 \dots$ – ciąg niezależnych zmiennych losowych o tym samym rozkładzie, $EX_i = \mu$, $D^2(X_i) = \sigma^2$.

Zgodnie z prawem wielkich liczb:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\text{pr. 1}} \mu$$

Możemy jednak ustandaryzować ciąg średnich:

$$U_n = \frac{\bar{X}_n - E\bar{X}_n}{D(\bar{X}_n)} = \frac{\bar{X}_n - \mu}{\sigma} \sqrt{n}$$

Do czego dąży U_n ?

Centralne Twierdzenie Graniczne

Twierdzenie Lindeberga-Levy'ego

Niech $X_1, X_2, X_3 \dots$ będzie ciągiem niezależnych zmiennych losowych o tym samym rozkładzie z $EX_i = \mu$ i $D^2(X_i) = \sigma^2$. Niech:

$$U_n = \frac{\bar{X}_n - E\bar{X}_n}{D(\bar{X}_n)} = \frac{\bar{X}_n - \mu}{\sigma} \sqrt{n}, \quad \text{gdzie } \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Wtedy:

$$\forall x \quad \lim_{n \rightarrow \infty} F_{U_n}(x) = \Phi(x),$$

gdzie Φ jest dystrybuantą standardowego rozkładu normalnego $N(0, 1)$.

Zjawisko zbiegania rozkładu standaryzowanej średniej do rozkładu normalnego jest **uniwersalne**!

Centralne Twierdzenie Graniczne

Twierdzenie Lindeberga-Levy'ego

Niech $X_1, X_2, X_3 \dots$ będzie ciągiem niezależnych zmiennych losowych o tym samym rozkładzie z $EX_i = \mu$ i $D^2(X_i) = \sigma^2$. Niech:

$$U_n = \frac{\bar{X}_n - E\bar{X}_n}{D(\bar{X}_n)} = \frac{\bar{X}_n - \mu}{\sigma} \sqrt{n}, \quad \text{gdzie } \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Wtedy:

$$\forall x \quad \lim_{n \rightarrow \infty} F_{U_n}(x) = \Phi(x),$$

gdzie Φ jest dystrybucją standardowego rozkładu normalnego $N(0, 1)$.


Zjawisko zbiegania rozkładu standaryzowanej średniej do rozkładu normalnego jest **uniwersalne**!

Rozkład normalny jest **powszechny**: powstaje ilekroć obserwowane zjawiska są wynikiem uśredniania wielu niezależnych losowych przyczynków.

Przykład: rozkład jednostajny $\text{Unif}[0, 1]$

X_1, X_2, X_3, \dots – niezależne zmienne $\sim \text{Unif}[0, 1]$


$$EX_i = \frac{1}{2}, \quad D^2(X_i) = \frac{1}{12}$$



Przykład: rozkład jednostajny $\text{Unif}[0, 1]$

X_1, X_2, X_3, \dots – niezależne zmienne $\sim \text{Unif}[0, 1]$

$$EX_i = \frac{1}{2}, \quad D^2(X_i) = \frac{1}{12}$$




$$S_n = X_1 + \dots + X_n, \quad U_n = \frac{S_n - ES_n}{D(S_n)} =$$

Przykład: rozkład jednostajny $\text{Unif}[0, 1]$


X_1, X_2, X_3, \dots – niezależne zmienne $\sim \text{Unif}[0, 1]$

$$EX_i = \frac{1}{2}, \quad D^2(X_i) = \frac{1}{12}$$




$$S_n = X_1 + \dots + X_n, \quad U_n = \frac{S_n - ES_n}{D(S_n)} = \frac{S_n - \frac{n}{2}}{\sqrt{\frac{n}{12}}}$$


Przykład: rozkład jednostajny $\text{Unif}[0, 1]$




Przykład: rozkład jednostajny $\text{Unif}[0, 1]$




Przykład: rozkład jednostajny $\text{Unif}[0, 1]$




Przykład: rozkład jednostajny $\text{Unif}[0, 1]$




Przykład: rozkład jednostajny $\text{Unif}[0, 1]$



Przykład: rozkład jednostajny $\text{Unif}[0, 1]$




Przykład: rozkład jednostajny $\text{Unif}[0, 1]$



Przykład: rozkład wykładniczy ($\lambda = 1$)

X_1, X_2, X_3, \dots – niezależne zmienne $\sim \text{Exp}(\lambda = 1)$


$$EX_i = \frac{1}{\lambda} = 1, \quad D^2(X_i) = \frac{1}{\lambda^2} = 1$$



Przykład: rozkład wykładniczy ($\lambda = 1$)

X_1, X_2, X_3, \dots – niezależne zmienne $\sim \text{Exp}(\lambda = 1)$

$$EX_i = \frac{1}{\lambda} = 1, \quad D^2(X_i) = \frac{1}{\lambda^2} = 1$$




$$S_n = X_1 + \dots + X_n, \quad U_n = \frac{S_n - ES_n}{D(S_n)} =$$

Przykład: rozkład wykładniczy ($\lambda = 1$)


X_1, X_2, X_3, \dots – niezależne zmienne $\sim \text{Exp}(\lambda = 1)$

$$EX_i = \frac{1}{\lambda} = 1, \quad D^2(X_i) = \frac{1}{\lambda^2} = 1$$




$$S_n = X_1 + \dots + X_n, \quad U_n = \frac{S_n - ES_n}{D(S_n)} = \frac{S_n - n}{\sqrt{n}}$$


Przykład: rozkład wykładniczy ($\lambda = 1$)




Przykład: rozkład wykładniczy ($\lambda = 1$)




Przykład: rozkład wykładniczy ($\lambda = 1$)




Przykład: rozkład wykładniczy ($\lambda = 1$)




Przykład: rozkład wykładniczy ($\lambda = 1$)




Przykład: rozkład wykładniczy ($\lambda = 1$)




Przykład: rozkład wykładniczy ($\lambda = 1$)




Przykład: rozkład wykładniczy ($\lambda = 1$)




Przykład: rozkład wykładniczy ($\lambda = 1$)



Przykład: rozkład wykładniczy ($\lambda = 1$)



Przykład: rozkład wykładniczy ($\lambda = 1$)



Zbieżność według dystrybuant

Mówimy, że ciąg zmiennych X_1, X_2, \dots jest zbieżny do zmiennej X :

- Z prawdopodobieństwem jeden (ozn. $X_n \xrightarrow{\text{pr. 1}} X$), gdy:

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

- Według prawdopodobieństwa (ozn. $X_n \xrightarrow{P} X$), gdy:

$$\forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) = 0$$

Zbieżność według dystrybuant

Mówimy, że ciąg zmiennych X_1, X_2, \dots jest zbieżny do zmiennej X :

- Z prawdopodobieństwem jeden (ozn. $X_n \xrightarrow{\text{pr. } 1} X$), gdy:

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

- Według prawdopodobieństwa (ozn. $X_n \xrightarrow{P} X$), gdy:

$$\forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) = 0$$

- Według dystrybuant (ozn. $X_n \xrightarrow{D} X$), gdy:

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x) \quad \text{w każdym punkcie ciągłości } F_X$$

Zbieżność według dystrybuant

Mówimy, że ciąg zmiennych X_1, X_2, \dots jest zbieżny do zmiennej X :

- Z prawdopodobieństwem jeden (ozn. $X_n \xrightarrow{\text{z pr. 1}} X$), gdy:

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

- Według prawdopodobieństwa (ozn. $X_n \xrightarrow{P} X$), gdy:

$$\forall \epsilon > 0 \quad \lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) = 0$$

- Według dystrybuant (ozn. $X_n \xrightarrow{D} X$), gdy:

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x) \quad \text{w każdym punkcie ciągłości } F_X$$

$$\text{Zachodzi: } X_n \xrightarrow{\text{z pr. 1}} X \Rightarrow X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{D} X,$$

czyli zbieżność według dystrybuant jest **najłabszym** z typów zbieżności

Podsumowanie

X_1, X_2, X_3, \dots – ciąg **niezależnych** zmiennych losowych o **tym samym rozkładzie** z wartością oczekiwaną $EX_i = \mu$ i wariancją $D^2(X_i) = \sigma^2$

$$\text{Definiujemy } \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

- Prawo Wielkich Liczb

$$\bar{X}_n \xrightarrow{\text{pr. 1}} \mu$$

- Centralne Twierdzenie Graniczne

$$\frac{\bar{X}_n - E\bar{X}_n}{D(\bar{X}_n)} = \frac{\bar{X}_n - \mu}{\sigma} \sqrt{n} \xrightarrow{D} U \sim N(0, 1)$$