

Metody probabilistyczne

13. Elementy statystyki matematycznej II

Wojciech Kotłowski

Instytut Informatyki PP
<http://www.cs.put.poznan.pl/wkotlowski/>

16.01.2018

Parametryczna rodzina rozkładów

Założymy teraz, że znany jest typ rozkładu cechy X w populacji, ale nie są znane jego parametry.

Parametryczna rodzina rozkładów

Założymy teraz, że znany jest typ rozkładu cechy X w populacji, ale nie są znane jego parametry.

Przykłady:

- $X \sim B(p)$, ale nie znamy wartości parametru p (jak w wyborach z dwoma kandydatami)
- $X \sim \text{Exp}(\lambda)$, ale nie znamy wartości λ (np. czas oczekiwania na zdarzenie)
- $X \sim N(\mu, \sigma^2)$, ale nie znamy wartości μ i σ^2 (np. rozkład wzrostu w populacji)

Mamy więc **rodzinę rozkładów** $\{P_\theta : \theta \in \Theta\}$ różniących się tylko wartością parametru θ , gdzie Θ jest zbiorem możliwych wartości parametru.

Funkcja wiarygodności

Niech cecha X ma rozkład P_θ należący do parametrycznej rodziny rozkładów.

Założmy, że w próbie zaobserwowaliśmy dane $\mathbf{x} = (x_1, x_2, \dots, x_n)$.

Funkcja wiarygodności

Niech cecha X ma rozkład P_θ należący do parametrycznej rodziny rozkładów.

Założmy, że w próbie zaobserwowaliśmy dane $\mathbf{x} = (x_1, x_2, \dots, x_n)$.

Funkcją wiarygodności $L(\mathbf{x}; \theta)$ nazywamy:

- Dla dyskretnej zmiennej X : łączne prawdopodobieństwo zaobserwowanych danych \mathbf{x} :

$$L(\mathbf{x}; \theta) = P_\theta(\mathbf{X} = \mathbf{x}) = p_\theta(x_1)p_\theta(x_2) \cdot \dots \cdot p_\theta(x_n),$$

gdzie używamy skrótowo $p_\theta(x_i) = P_\theta(X_i = x_i)$

Funkcja wiarygodności

Niech cecha X ma rozkład P_θ należący do parametrycznej rodziny rozkładów.

Założmy, że w próbie zaobserwowaliśmy dane $\mathbf{x} = (x_1, x_2, \dots, x_n)$.

Funkcją wiarygodności $L(\mathbf{x}; \theta)$ nazywamy:

- Dla **dyskretnej** zmiennej X : łączne prawdopodobieństwo zaobserwowanych danych \mathbf{x} :

$$L(\mathbf{x}; \theta) = P_\theta(\mathbf{X} = \mathbf{x}) = p_\theta(x_1)p_\theta(x_2) \cdot \dots \cdot p_\theta(x_n),$$

gdzie używamy skrótowo $p_\theta(x_i) = P_\theta(X_i = x_i)$

- Dla **ciągłej** zmiennej losowej X : łączną gęstość prawdopodobieństwa zaobserwowanych danych \mathbf{x} :

$$L(\mathbf{x}; \theta) = f_{\mathbf{X}; \theta}(\mathbf{x}) = f_\theta(x_1)f_\theta(x_2) \cdot \dots \cdot f_\theta(x_n)$$

Funkcja wiarygodności

Niech cecha X ma rozkład P_θ należący do parametrycznej rodziny rozkładów.

Założmy, że w próbie zaobserwowaliśmy dane $\mathbf{x} = (x_1, x_2, \dots, x_n)$.

Funkcją wiarygodności $L(\mathbf{x}; \theta)$ nazywamy:

- Dla **dyskretnej** zmiennej X : łączne prawdopodobieństwo zaobserwowanych danych \mathbf{x} :

$$L(\mathbf{x}; \theta) = P_\theta(\mathbf{X} = \mathbf{x}) = p_\theta(x_1)p_\theta(x_2) \cdot \dots \cdot p_\theta(x_n),$$

gdzie używamy skrótowo $p_\theta(x_i) = P_\theta(X_i = x_i)$

- Dla **ciągłej** zmiennej losowej X : łączną gęstość prawdopodobieństwa zaobserwowanych danych \mathbf{x} :

$$L(\mathbf{x}; \theta) = f_{\mathbf{X}; \theta}(\mathbf{x}) = f_\theta(x_1)f_\theta(x_2) \cdot \dots \cdot f_\theta(x_n)$$

Uwaga: funkcja wiarygodności jest funkcją **danych** i **parametru** θ

Estymacja metodą największej wiarygodności

Estymatorem największej wiarygodności (NW) parametru θ nazywamy estymator równy parametrowi, który maksymalizuje funkcję wiarygodności:

$$\hat{\theta}(\mathbf{x}) = \operatorname{argmax}_{\theta} L(\mathbf{x}; \theta)$$

Estymator NW szacuje nieznaną wartość parametru poprzez wybór wartości parametru, przy którym zaobserwowane dane są najbardziej prawdopodobne!

Estymacja metodą największej wiarygodności

Estymatorem największej wiarygodności (NW) parametru θ nazywamy estymator równy parametrowi, który maksymalizuje funkcję wiarygodności:

$$\hat{\theta}(\mathbf{x}) = \operatorname{argmax}_{\theta} L(\mathbf{x}; \theta)$$

Estymator NW szacuje nieznaną wartość parametru poprzez wybór wartości parametru, przy którym zaobserwowane dane są najbardziej prawdopodobne!

Uwaga: zwykle znacznie wygodniejsze bywa działanie na **ujemnym logarytmie wiarygodności** – $-\ln L(\mathbf{x}; \theta)$. Ponieważ L ma maksimum wtedy i tylko wtedy gdy $-\ln L$ ma minimum, możemy alternatywnie zdefiniować:

$$\hat{\theta}(\mathbf{x}) = \operatorname{argmin}_{\theta} -\ln L(\mathbf{x}; \theta)$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować nieznaną wartość oczekiwaną μ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \mu) = \prod_{i=1}^n f_{\mu}(x_i)$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować nieznaną wartość oczekiwaną μ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \mu) = \prod_{i=1}^n f_{\mu}(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować nieznaną wartość oczekiwaną μ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \mu) = \prod_{i=1}^n f_{\mu}(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$-\ln L(\mathbf{x}; \mu) = -n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować nieznaną wartość oczekiwaną μ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \mu) = \prod_{i=1}^n f_{\mu}(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$-\ln L(\mathbf{x}; \mu) = -n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

- Aby znaleźć **minimum** funkcji $-\ln L(\mathbf{x}; \mu)$ liczymy pochodną po μ i przyrównujemy ją do zera:

$$\frac{\partial}{\partial \mu} -\ln L(\mathbf{x}; \mu) = \sum_{i=1}^n \frac{\mu - x_i}{\sigma^2}$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować nieznaną wartość oczekiwaną μ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \mu) = \prod_{i=1}^n f_{\mu}(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$-\ln L(\mathbf{x}; \mu) = -n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

- Aby znaleźć **minimum** funkcji $-\ln L(\mathbf{x}; \mu)$ liczymy pochodną po μ i przyrównujemy ją do zera:

$$\frac{\partial}{\partial \mu} -\ln L(\mathbf{x}; \mu) = \sum_{i=1}^n \frac{\mu - x_i}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (\mu - x_i)$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować nieznaną wartość oczekiwaną μ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \mu) = \prod_{i=1}^n f_{\mu}(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$-\ln L(\mathbf{x}; \mu) = -n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

- Aby znaleźć **minimum** funkcji $-\ln L(\mathbf{x}; \mu)$ liczymy pochodną po μ i przyrównujemy ją do zera:

$$\frac{\partial}{\partial \mu} -\ln L(\mathbf{x}; \mu) = \sum_{i=1}^n \frac{\mu - x_i}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (\mu - x_i)$$

$$\frac{1}{\sigma^2} \sum_{i=1}^n (\mu - x_i) = 0 \iff \mu = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}_n$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować nieznaną wartość oczekiwaną μ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \mu) = \prod_{i=1}^n f_{\mu}(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$-\ln L(\mathbf{x}; \mu) = -n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

- Aby znaleźć **minimum** funkcji $-\ln L(\mathbf{x}; \mu)$ liczymy pochodną po μ i przyrównujemy ją do zera:

$$\frac{\partial}{\partial \mu} -\ln L(\mathbf{x}; \mu) = \sum_{i=1}^n \frac{\mu - x_i}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (\mu - x_i)$$

$$\frac{1}{\sigma^2} \sum_{i=1}^n (\mu - x_i) = 0 \iff \mu = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}_n$$

- **Wniosek:** estymatorem NW parametru μ w rozkładzie normalnym jest średnia arytmetyczna z próby $\hat{\mu} = \bar{X}_n$.

Przykład: rozkład wykładniczy

- $X \sim \text{Exp}(\lambda)$ i chcemy estymować nieznany parametr λ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i}$$

Przykład: rozkład wykładniczy

- $X \sim \text{Exp}(\lambda)$ i chcemy estymować nieznany parametr λ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda(x_1 + \dots + x_n)}$$

Przykład: rozkład wykładniczy

- $X \sim \text{Exp}(\lambda)$ i chcemy estymować nieznany parametr λ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda(x_1 + \dots + x_n)} = \lambda^n e^{-n\lambda \bar{x}_n}$$

Przykład: rozkład wykładniczy

- $X \sim \text{Exp}(\lambda)$ i chcemy estymować nieznany parametr λ .
- Funkcja wiarygodności:

$$\begin{aligned} L(\mathbf{x}; \lambda) &= \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda(x_1 + \dots + x_n)} = \lambda^n e^{-n\lambda \bar{x}_n} \\ -\ln L(\mathbf{x}; \lambda) &= -n \ln \lambda + n\lambda \bar{x}_n \end{aligned}$$

Przykład: rozkład wykładniczy

- $X \sim \text{Exp}(\lambda)$ i chcemy estymować nieznany parametr λ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda(x_1 + \dots + x_n)} = \lambda^n e^{-n\lambda \bar{x}_n}$$

$$-\ln L(\mathbf{x}; \lambda) = -n \ln \lambda + n\lambda \bar{x}_n$$

- Przyprowadzenie pochodnej do zera:

$$\frac{\partial}{\partial \lambda} -\ln L(\mathbf{x}; \lambda) = -\frac{n}{\lambda} + n\bar{x}_n$$

Przykład: rozkład wykładniczy

- $X \sim \text{Exp}(\lambda)$ i chcemy estymować nieznany parametr λ .
- Funkcja wiarygodności:

$$L(\mathbf{x}; \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda(x_1 + \dots + x_n)} = \lambda^n e^{-n\lambda \bar{x}_n}$$

$$-\ln L(\mathbf{x}; \lambda) = -n \ln \lambda + n\lambda \bar{x}_n$$

- Przyprowadzenie pochodnej do zera:

$$\frac{\partial}{\partial \lambda} -\ln L(\mathbf{x}; \lambda) = -\frac{n}{\lambda} + n\bar{x}_n$$

$$\frac{\partial}{\partial \lambda} -\ln L(\mathbf{x}; \lambda) = 0 \iff \lambda = \frac{1}{\bar{x}_n}$$

Przykład: rozkład wykładniczy

- $X \sim \text{Exp}(\lambda)$ i chcemy estymować nieznany parametr λ .
- Funkcja wiarygodności:

$$\begin{aligned} L(\mathbf{x}; \lambda) &= \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda(x_1 + \dots + x_n)} = \lambda^n e^{-n\lambda \bar{x}_n} \\ -\ln L(\mathbf{x}; \lambda) &= -n \ln \lambda + n\lambda \bar{x}_n \end{aligned}$$

- Przyprowadzenie pochodnej do zera:

$$\begin{aligned} \frac{\partial}{\partial \lambda} -\ln L(\mathbf{x}; \lambda) &= -\frac{n}{\lambda} + n\bar{x}_n \\ \frac{\partial}{\partial \lambda} -\ln L(\mathbf{x}; \lambda) &= 0 \iff \lambda = \frac{1}{\bar{x}_n} \end{aligned}$$

- **Wniosek:** estymator NW parametru λ w rozkładzie wykładniczym:

$$\hat{\lambda} = \frac{1}{\bar{X}_n}$$

Przykład: rozkład dwupunktowy

- $X \sim B(p)$ i chcemy estymować nieznany parametr p .
- Załóżmy że wśród n obserwacji jest k jedynek i $n - k$ zer

Przykład: rozkład dwupunktowy

- $X \sim B(p)$ i chcemy estymować nieznany parametr p .
- Załóżmy że wśród n obserwacji jest k jedynek i $n - k$ zer

$$L(\mathbf{x}; p) = \prod_{i=1}^n p(x_i)$$

Przykład: rozkład dwupunktowy

- $X \sim B(p)$ i chcemy estymować nieznany parametr p .
- Załóżmy że wśród n obserwacji jest k jedynek i $n - k$ zer

$$L(\mathbf{x}; p) = \prod_{i=1}^n p(x_i) = p(1)^k p(0)^{n-k}$$

Przykład: rozkład dwupunktowy

- $X \sim B(p)$ i chcemy estymować nieznany parametr p .
- Załóżmy że wśród n obserwacji jest k jedynek i $n - k$ zer

$$L(\mathbf{x}; p) = \prod_{i=1}^n p(x_i) = p(1)^k p(0)^{n-k} = p^k (1-p)^{n-k}$$

Przykład: rozkład dwupunktowy

- $X \sim B(p)$ i chcemy estymować nieznany parametr p .
- Załóżmy że wśród n obserwacji jest k jedynek i $n - k$ zer

$$L(\mathbf{x}; p) = \prod_{i=1}^n p(x_i) = p(1)^k p(0)^{n-k} = p^k (1-p)^{n-k}$$

$$-\ln L(\mathbf{x}; p) = -k \ln p - (n - k) \ln(1 - p)$$

Przykład: rozkład dwupunktowy

- $X \sim B(p)$ i chcemy estymować nieznaną wartość parametru p .
- Załóżmy że wśród n obserwacji jest k jedynek i $n - k$ zer

$$L(\mathbf{x}; p) = \prod_{i=1}^n p(x_i) = p(1)^k p(0)^{n-k} = p^k (1-p)^{n-k}$$

$$-\ln L(\mathbf{x}; p) = -k \ln p - (n-k) \ln(1-p)$$

- Przyprowadzenie pochodnej do zera:

$$\frac{\partial}{\partial p} -\ln L(\mathbf{x}; p) = -\frac{k}{p} + \frac{n-k}{1-p}$$

Przykład: rozkład dwupunktowy

- $X \sim B(p)$ i chcemy estymować nieznaną wartość parametru p .
- Załóżmy że wśród n obserwacji jest k jedynek i $n - k$ zer

$$L(\mathbf{x}; p) = \prod_{i=1}^n p(x_i) = p(1)^k p(0)^{n-k} = p^k (1-p)^{n-k}$$

$$-\ln L(\mathbf{x}; p) = -k \ln p - (n-k) \ln(1-p)$$

- Przyprowadzenie pochodnej do zera:

$$\frac{\partial}{\partial p} -\ln L(\mathbf{x}; p) = -\frac{k}{p} + \frac{n-k}{1-p}$$

$$\frac{\partial}{\partial p} -\ln L(\mathbf{x}; p) = 0 \iff \frac{k}{p} = \frac{n-k}{1-p}$$

Przykład: rozkład dwupunktowy

- $X \sim B(p)$ i chcemy estymować nieznaną wartość parametru p .
- Załóżmy że wśród n obserwacji jest k jedynek i $n - k$ zer

$$L(\mathbf{x}; p) = \prod_{i=1}^n p(x_i) = p(1)^k p(0)^{n-k} = p^k (1-p)^{n-k}$$

$$-\ln L(\mathbf{x}; p) = -k \ln p - (n-k) \ln(1-p)$$

- Przyprowadzenie pochodnej do zera:

$$\frac{\partial}{\partial p} -\ln L(\mathbf{x}; p) = -\frac{k}{p} + \frac{n-k}{1-p}$$

$$\frac{\partial}{\partial p} -\ln L(\mathbf{x}; p) = 0 \iff \frac{k}{p} = \frac{n-k}{1-p} \iff p = \frac{k}{n}$$

Przykład: rozkład dwupunktowy

- $X \sim B(p)$ i chcemy estymować nieznaną wartość parametru p .
- Załóżmy że wśród n obserwacji jest k jedynek i $n - k$ zer

$$L(\mathbf{x}; p) = \prod_{i=1}^n p(x_i) = p(1)^k p(0)^{n-k} = p^k (1-p)^{n-k}$$

$$-\ln L(\mathbf{x}; p) = -k \ln p - (n-k) \ln(1-p)$$

- Przyprowadzenie pochodnej do zera:

$$\frac{\partial}{\partial p} -\ln L(\mathbf{x}; p) = -\frac{k}{p} + \frac{n-k}{1-p}$$

$$\frac{\partial}{\partial p} -\ln L(\mathbf{x}; p) = 0 \iff \frac{k}{p} = \frac{n-k}{1-p} \iff p = \frac{k}{n}$$

- **Wniosek:** estymator ML parametru p w rozkładzie dwupunktowym jest **częstość empiryczna**

$$\hat{p} = \frac{|\{i: X_i = 1\}|}{n}$$

Przykład: rozkład dwupunktowy

- $X \sim B(p)$ i chcemy estymować nieznaną wartość parametru p .
- Załóżmy że wśród n obserwacji jest k jedynek i $n - k$ zer

$$L(\mathbf{x}; p) = \prod_{i=1}^n p(x_i) = p(1)^k p(0)^{n-k} = p^k (1-p)^{n-k}$$

$$-\ln L(\mathbf{x}; p) = -k \ln p - (n-k) \ln(1-p)$$

- Przyprowadzenie pochodnej do zera:

$$\frac{\partial}{\partial p} -\ln L(\mathbf{x}; p) = -\frac{k}{p} + \frac{n-k}{1-p}$$

$$\frac{\partial}{\partial p} -\ln L(\mathbf{x}; p) = 0 \iff \frac{k}{p} = \frac{n-k}{1-p} \iff p = \frac{k}{n}$$

- **Wniosek:** estymator ML parametru p w rozkładzie dwupunktowym jest **częstość empiryczna**

$$\hat{p} = \frac{|\{i: X_i = 1\}|}{n} = \bar{X}_n$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować zarówno μ jak i σ^2 .
- Funkcję wiarygodności policzyliśmy już wcześniej:

$$-\ln L(\mathbf{x}; \mu, \sigma^2) = -n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować zarówno μ jak i σ^2 .
- Funkcję wiarygodności policzyliśmy już wcześniej:

$$\begin{aligned} -\ln L(\mathbf{x}; \mu, \sigma^2) &= -n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \\ &= \frac{1}{2} n \ln \sigma^2 + n \ln \sqrt{2\pi} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować zarówno μ jak i σ^2 .
- Funkcję wiarygodności policzyliśmy już wcześniej:

$$\begin{aligned} -\ln L(\mathbf{x}; \mu, \sigma^2) &= -n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \\ &= \frac{1}{2} n \ln \sigma^2 + n \ln \sqrt{2\pi} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

- Aby znaleźć minimum funkcji $-\ln L(\mathbf{x}; \mu, \sigma^2)$ przyrównujemy pochodne po μ i σ^2 do zera.

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować **zarówno** μ jak i σ^2 .
- Funkcję wiarygodności policzyliśmy już wcześniej:

$$\begin{aligned} -\ln L(\mathbf{x}; \mu, \sigma^2) &= -n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \\ &= \frac{1}{2} n \ln \sigma^2 + n \ln \sqrt{2\pi} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

- Aby znaleźć **minimum** funkcji $-\ln L(\mathbf{x}; \mu, \sigma^2)$ przyrównujemy pochodne **po** μ i σ^2 do zera.

Pochodną po μ policzyliśmy już wcześniej:

$$\frac{\partial}{\partial \mu} -\ln L(\mathbf{x}; \mu, \sigma^2) = 0 \quad \Longleftrightarrow \quad \mu = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}_n$$

Przykład: rozkład normalny

- $X \sim N(\mu, \sigma^2)$ i chcemy estymować **zarówno μ jak i σ^2** .
- Funkcję wiarygodności policzyliśmy już wcześniej:

$$\begin{aligned} -\ln L(\mathbf{x}; \mu, \sigma^2) &= -n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \\ &= \frac{1}{2} n \ln \sigma^2 + n \ln \sqrt{2\pi} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

- Aby znaleźć **minimum** funkcji $-\ln L(\mathbf{x}; \mu, \sigma^2)$ przyrównujemy pochodne **po μ i σ^2** do zera.

Pochodną po μ policzyliśmy już wcześniej:

$$\frac{\partial}{\partial \mu} -\ln L(\mathbf{x}; \mu, \sigma^2) = 0 \quad \Longleftrightarrow \quad \mu = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}_n$$

Pozostaje nam policzyć pochodną po σ^2 .

Przykład: rozkład normalny – c.d.

$$-\ln L(\mathbf{x}; \mu, \sigma^2) = \frac{1}{2}n \ln \sigma^2 + n \ln \sqrt{2\pi} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

Przykład: rozkład normalny – c.d.

$$-\ln L(\mathbf{x}; \mu, \sigma^2) = \frac{1}{2}n \ln \sigma^2 + n \ln \sqrt{2\pi} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

$$\frac{\partial}{\partial \sigma^2} -\ln L(\mathbf{x}; \mu, \sigma^2) = \frac{1}{2} \frac{n}{\sigma^2} - \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$$

Przykład: rozkład normalny – c.d.

$$-\ln L(\mathbf{x}; \mu, \sigma^2) = \frac{1}{2}n \ln \sigma^2 + n \ln \sqrt{2\pi} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

$$\frac{\partial}{\partial \sigma^2} -\ln L(\mathbf{x}; \mu, \sigma^2) = \frac{1}{2} \frac{n}{\sigma^2} - \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$$

Przyrównując pochodną do zera dostajemy:

$$\frac{1}{2} \frac{n}{\sigma^2} = \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$$

Przykład: rozkład normalny – c.d.

$$-\ln L(\mathbf{x}; \mu, \sigma^2) = \frac{1}{2}n \ln \sigma^2 + n \ln \sqrt{2\pi} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

$$\frac{\partial}{\partial \sigma^2} -\ln L(\mathbf{x}; \mu, \sigma^2) = \frac{1}{2} \frac{n}{\sigma^2} - \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$$

Przyrównując pochodną do zera dostajemy:

$$\frac{1}{2} \frac{n}{\sigma^2} = \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 \iff \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

Przykład: rozkład normalny – c.d.

$$-\ln L(\mathbf{x}; \mu, \sigma^2) = \frac{1}{2}n \ln \sigma^2 + n \ln \sqrt{2\pi} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}$$

$$\frac{\partial}{\partial \sigma^2} -\ln L(\mathbf{x}; \mu, \sigma^2) = \frac{1}{2} \frac{n}{\sigma^2} - \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$$

Przyrównując pochodną do zera dostajemy:

$$\frac{1}{2} \frac{n}{\sigma^2} = \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 \iff \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

Wniosek: estymatory NW parametrów μ i σ^2 w rozkładzie normalnym:

$$\hat{\mu} = \bar{X}_n, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Estymator wariancji jest **obciążony**

Zadanie

Zadanie 1

Wyznacz estymator największej wiarygodności parametru λ dla rozkład Poissona

Własności estymatora największej wiarygodności

Estymatory największej wiarygodności mogą być czasem kłopotliwe do wyznaczenia (wymagają rozwiązania problemu optymalizacji), mają jednak pożądane własności **asymptotyczne** (tzn. dla $n \rightarrow \infty$):

- Zgodność
- Asymptotyczna nieobciążoność
- Asymptotyczna efektywność

Estymacja przedziałowa

Dotychczas rozważaliśmy tzw. **estymatory punktowe**, które szacują wartość parametru θ za pomocą jednej liczby $\hat{\theta}$.

Estymacja przedziałowa

Dotychczas rozważaliśmy tzw. **estymatory punktowe**, które szacują wartość parametru θ za pomocą jednej liczby $\hat{\theta}$.

Często chcemy mieć nie tylko oszacowanie parametru θ , ale również **przedział**, w którym (z dużym prawdopodobieństwem) θ się znajdzie:

$$[\hat{\theta}_L, \hat{\theta}_P]$$

Taki przedział nazywamy **przedziałem ufności**, a zadanie jego wyznaczenia nazywamy **estymacją przedziałową**.

Estymacja przedziałowa

Dotychczas rozważaliśmy tzw. **estymatory punktowe**, które szacują wartość parametru θ za pomocą jednej liczby $\hat{\theta}$.

Często chcemy mieć nie tylko oszacowanie parametru θ , ale również **przedział**, w którym (z dużym prawdopodobieństwem) θ się znajdzie:

$$[\hat{\theta}_L, \hat{\theta}_P]$$

Taki przedział nazywamy **przedziałem ufności**, a zadanie jego wyznaczenia nazywamy **estymacją przedziałową**.

Zaletą przedziału ufności jest **wskazanie stopnia dokładności** oszacowania parametru.

Przedział ufności

Przedziałem ufności dla parametru θ na **poziomie ufności** $1 - \alpha$ nazywamy przedział $[\hat{\theta}_L, \hat{\theta}_P]$ taki, że $\hat{\theta}_L$ i $\hat{\theta}_P$ są statystykami wyznaczonymi z próby, oraz:

$$P\left(\hat{\theta}_L \leq \theta \leq \hat{\theta}_P\right) = 1 - \alpha$$

Przedział ufności

Przedziałem ufności dla parametru θ na **poziomie ufności** $1 - \alpha$ nazywamy przedział $[\hat{\theta}_L, \hat{\theta}_P]$ taki, że $\hat{\theta}_L$ i $\hat{\theta}_P$ są statystykami wyznaczonymi z próby, oraz:

$$P\left(\hat{\theta}_L \leq \theta \leq \hat{\theta}_P\right) = 1 - \alpha$$

- Z prawdopodobieństwem $1 - \alpha$ prawdziwa wartość parametru znajduje się w przedziale

Przedział ufności

Przedziałem ufności dla parametru θ na **poziomie ufności** $1 - \alpha$ nazywamy przedział $[\hat{\theta}_L, \hat{\theta}_P]$ taki, że $\hat{\theta}_L$ i $\hat{\theta}_P$ są statystykami wyznaczonymi z próby, oraz:

$$P\left(\hat{\theta}_L \leq \theta \leq \hat{\theta}_P\right) = 1 - \alpha$$

- Z prawdopodobieństwem $1 - \alpha$ prawdziwa wartość parametru znajduje się w przedziale
- **Uwaga:** to przedział jest losowy, a nie wartość parametru!

Przedział ufności

Przedziałem ufności dla parametru θ na **poziomie ufności** $1 - \alpha$ nazywamy przedział $[\hat{\theta}_L, \hat{\theta}_P]$ taki, że $\hat{\theta}_L$ i $\hat{\theta}_P$ są statystykami wyznaczonymi z próby, oraz:

$$P\left(\hat{\theta}_L \leq \theta \leq \hat{\theta}_P\right) = 1 - \alpha$$

- Z prawdopodobieństwem $1 - \alpha$ prawdziwa wartość parametru znajduje się w przedziale
- **Uwaga:** to przedział jest losowy, a nie wartość parametru!
- Czasem α (zamiast $1 - \alpha$) nazywa się poziomem ufności

Przedział ufności

Przedziałem ufności dla parametru θ na **poziomie ufności** $1 - \alpha$ nazywamy przedział $[\hat{\theta}_L, \hat{\theta}_P]$ taki, że $\hat{\theta}_L$ i $\hat{\theta}_P$ są statystykami wyznaczonymi z próby, oraz:

$$P\left(\hat{\theta}_L \leq \theta \leq \hat{\theta}_P\right) = 1 - \alpha$$

- Z prawdopodobieństwem $1 - \alpha$ prawdziwa wartość parametru znajduje się w przedziale
- **Uwaga:** to przedział jest losowy, a nie wartość parametru!
- Czasem α (zamiast $1 - \alpha$) nazywa się poziomem ufności
- Czasem używam się przedziału otwartego $(\hat{\theta}_L, \hat{\theta}_P)$

Przedział ufności

Przedziałem ufności dla parametru θ na **poziomie ufności** $1 - \alpha$ nazywamy przedział $[\hat{\theta}_L, \hat{\theta}_P]$ taki, że $\hat{\theta}_L$ i $\hat{\theta}_P$ są statystykami wyznaczonymi z próby, oraz:

$$P\left(\hat{\theta}_L \leq \theta \leq \hat{\theta}_P\right) = 1 - \alpha$$

- Z prawdopodobieństwem $1 - \alpha$ prawdziwa wartość parametru znajduje się w przedziale
- **Uwaga:** to przedział jest losowy, a nie wartość parametru!
- Czasem α (zamiast $1 - \alpha$) nazywa się poziomem ufności
- Czasem używam się przedziału otwartego $(\hat{\theta}_L, \hat{\theta}_P)$
- **Przykład:** W problemie szacowania poparcia kandydata A, estymacja przedziałowa dała przedział ufności na poziomie 95% równy $[0.58, 0.62]$, tzn. z prawdopodobieństwem 95% prawdziwy parametr p znajduje się między 0.58 a 0.62.

Metody wyznaczania przedziałów ufności

Zwykle rozpinamy przedział symetrycznie wokół pewnego estymatora punktowego $\hat{\theta}$:

$$[\hat{\theta} - \Delta, \hat{\theta} + \Delta], \quad \text{tzn. } \hat{\theta}_L = \hat{\theta} - \Delta, \quad \hat{\theta}_P = \hat{\theta} + \Delta$$

Rozpiętość przedziału Δ wyznaczana jest w oparciu o docelowy poziom ufności, tzn. rozwiązując równanie (ze względu na Δ):

$$1 - \alpha = P(\hat{\theta} - \Delta \leq \theta \leq \hat{\theta} + \Delta)$$

Metody wyznaczania przedziałów ufności

Zwykle rozpinamy przedział symetrycznie wokół pewnego estymatora punktowego $\hat{\theta}$:

$$[\hat{\theta} - \Delta, \hat{\theta} + \Delta], \quad \text{tzn. } \hat{\theta}_L = \hat{\theta} - \Delta, \quad \hat{\theta}_P = \hat{\theta} + \Delta$$

Rozpiętość przedziału Δ wyznaczana jest w oparciu o docelowy poziom ufności, tzn. rozwiązując równanie (ze względu na Δ):

$$\begin{aligned} 1 - \alpha &= P(\hat{\theta} - \Delta \leq \theta \leq \hat{\theta} + \Delta) \\ &= P(-\Delta \leq \theta - \hat{\theta} \leq \Delta) \end{aligned}$$

Metody wyznaczania przedziałów ufności

Zwykle rozpinamy przedział symetrycznie wokół pewnego estymatora punktowego $\hat{\theta}$:

$$[\hat{\theta} - \Delta, \hat{\theta} + \Delta], \quad \text{tzn. } \hat{\theta}_L = \hat{\theta} - \Delta, \quad \hat{\theta}_P = \hat{\theta} + \Delta$$

Rozpiętość przedziału Δ wyznaczana jest w oparciu o docelowy poziom ufności, tzn. rozwiązując równanie (ze względu na Δ):

$$\begin{aligned} 1 - \alpha &= P(\hat{\theta} - \Delta \leq \theta \leq \hat{\theta} + \Delta) \\ &= P(-\Delta \leq \theta - \hat{\theta} \leq \Delta) \\ &= P(-\Delta \leq \hat{\theta} - \theta \leq \Delta) \end{aligned}$$

Przykład: rozkład normalny ze znaną wariancją

Niech $X \sim N(\mu, \sigma^2)$, gdzie σ^2 jest **znana**

Przykład: rozkład normalny ze znaną wariancją

Niech $X \sim N(\mu, \sigma^2)$, gdzie σ^2 jest **znana**

Konstruujemy estymator wartości oczekiwanej μ na podstawie próby X_1, \dots, X_n :

$$\hat{\mu} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Przykład: rozkład normalny ze znaną wariancją

Niech $X \sim N(\mu, \sigma^2)$, gdzie σ^2 jest **znana**

Konstruujemy estymator wartości oczekiwanej μ na podstawie próby X_1, \dots, X_n :

$$\hat{\mu} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Ponieważ \bar{X}_n jest kombinacją liniową niezależnych zmiennych o rozkładzie normalnym, \bar{X}_n **ma rozkład normalny** z parametrami:

$$E(\bar{X}_n) = \mu, \quad D^2(\bar{X}_n) = \frac{\sigma^2}{n}, \quad \text{czyli } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Przykład: rozkład normalny ze znaną wariancją

Niech $X \sim N(\mu, \sigma^2)$, gdzie σ^2 jest **znana**

Konstruujemy estymator wartości oczekiwanej μ na podstawie próby X_1, \dots, X_n :

$$\hat{\mu} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$


Ponieważ \bar{X}_n jest kombinacją liniową niezależnych zmiennych o rozkładzie normalnym, \bar{X}_n **ma rozkład normalny** z parametrami:

$$E(\bar{X}_n) = \mu, \quad D^2(\bar{X}_n) = \frac{\sigma^2}{n}, \quad \text{czyli } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Konstruujemy następnie przedział ufności na poziomie ufności $1 - \alpha$:


$$1 - \alpha = P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right)$$

Rozkład estymatora \overline{X}_n



Rozkład estymatora \bar{X}_n

$$P\left(\mu - \Delta \leq \bar{X}_n \leq \mu + \Delta\right) = 1 - \alpha$$



Przykład: rozkład normalny ze znaną wariancją

$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Przykład: rozkład normalny ze znaną wariancją

$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$1 - \alpha = P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right)$$

Przykład: rozkład normalny ze znaną wariancją

$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$\begin{aligned} 1 - \alpha &= P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right) \\ &= P\left(-\frac{\Delta}{\sigma}\sqrt{n} \leq \frac{\bar{X}_n - \mu}{\sigma}\sqrt{n} \leq \frac{\Delta}{\sigma}\sqrt{n}\right) \end{aligned}$$

Przykład: rozkład normalny ze znaną wariancją

$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$\begin{aligned} 1 - \alpha &= P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right) \\ &= P\left(-\frac{\Delta}{\sigma}\sqrt{n} \leq \frac{\bar{X}_n - \mu}{\sigma}\sqrt{n} \leq \frac{\Delta}{\sigma}\sqrt{n}\right) \\ &= P\left(-\frac{\Delta}{\sigma}\sqrt{n} \leq Z \leq \frac{\Delta}{\sigma}\sqrt{n}\right) \end{aligned}$$

Przykład: rozkład normalny ze znaną wariancją


$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$\begin{aligned} 1 - \alpha &= P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right) \\ &= P\left(-\frac{\Delta}{\sigma}\sqrt{n} \leq \frac{\bar{X}_n - \mu}{\sigma}\sqrt{n} \leq \frac{\Delta}{\sigma}\sqrt{n}\right) \\ &= P\left(-\frac{\Delta}{\sigma}\sqrt{n} \leq Z \leq \frac{\Delta}{\sigma}\sqrt{n}\right) \\ &= \Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) - \Phi\left(-\frac{\Delta}{\sigma}\sqrt{n}\right) \end{aligned}$$

Przykład: rozkład normalny ze znaną wariancją

$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$\begin{aligned} 1 - \alpha &= P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right) \\ &= P\left(-\frac{\Delta}{\sigma}\sqrt{n} \leq \frac{\bar{X}_n - \mu}{\sigma}\sqrt{n} \leq \frac{\Delta}{\sigma}\sqrt{n}\right) \\ &= P\left(-\frac{\Delta}{\sigma}\sqrt{n} \leq Z \leq \frac{\Delta}{\sigma}\sqrt{n}\right) \\ &= \Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) - \Phi\left(-\frac{\Delta}{\sigma}\sqrt{n}\right) \\ &= 2\Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) - 1 \end{aligned}$$


$$\Phi(-x) = 1 - \Phi(x)$$

Przykład: rozkład normalny ze znaną wariancją

$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$1 - \alpha = 2\Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) - 1$$

Przykład: rozkład normalny ze znaną wariancją

$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$1 - \alpha = 2\Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) - 1$$

$$\Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) = 1 - \frac{\alpha}{2}$$

Przykład: rozkład normalny ze znaną wariancją

$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$1 - \alpha = 2\Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) - 1$$

$$\Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) = 1 - \frac{\alpha}{2}$$

$$\frac{\Delta}{\sigma}\sqrt{n} = \underbrace{\Phi^{-1}\left(1 - \frac{\alpha}{2}\right)}_{z_{1-\alpha/2}}$$

Przykład: rozkład normalny ze znaną wariancją

$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$1 - \alpha = 2\Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) - 1$$

$$\Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) = 1 - \frac{\alpha}{2}$$

$$\frac{\Delta}{\sigma}\sqrt{n} = \underbrace{\Phi^{-1}\left(1 - \frac{\alpha}{2}\right)}_{z_{1-\alpha/2}}$$

$$\Delta = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

Przykład: rozkład normalny ze znaną wariancją

$$\text{Skoro } \bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{to } Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$\begin{aligned} 1 - \alpha &= 2\Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) - 1 \\ \Phi\left(\frac{\Delta}{\sigma}\sqrt{n}\right) &= 1 - \frac{\alpha}{2} \\ \frac{\Delta}{\sigma}\sqrt{n} &= \underbrace{\Phi^{-1}\left(1 - \frac{\alpha}{2}\right)}_{z_{1-\alpha/2}} \\ \Delta &= z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \end{aligned}$$


Uwaga: $z_{1-\alpha/2}$ jest **kwantylem rzędu $1 - \frac{\alpha}{2}$** rozkładu normalnego standardowego

Kwantyl (uproszczona definicja!)

Rozważmy zmienną losową X ze ściśle rosnącą dystrybuantą.

Kwantylem rzędu p zmiennej X nazywamy liczbę $x_p \in \mathbb{R}$ taką, że:

$$F_X(x_p) = P(X \leq x_p) = p, \quad \text{czyli } x_p = F_X^{-1}(p)$$



Kwantyl x_p otrzymujemy poprzez wyznaczenia wartości dystrybuanty odwrotnej (tzw. funkcji kwantylowej) w p

Kwantyl z_p dla $Z \sim N(0, 1)$ a tablica wartości $\Phi(z)$

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.00	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.10	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5674	0.5714	0.5753
0.20	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.30	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.40	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.50	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.60	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.70	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.80	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.90	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.00	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.10	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.20	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.30	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.40	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.50	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.60	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.70	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.80	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.90	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.00	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.10	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.20	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.30	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.40	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.50	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.60	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.70	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.80	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.90	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.00	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.10	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.20	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.30	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.40	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

Kwantyl z_p dla $Z \sim N(0, 1)$ a tablica wartości $\Phi(z)$

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.00	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.10	0.5398	0.5438	0.5478	0.5517	0.5557					
0.20	0.5793	0.5832	0.5871	0.5910	0.5948					
0.30	0.6179	0.6217	0.6255	0.6293	0.6331					
0.40	0.6554	0.6591	0.6628	0.6664	0.6700					
0.50	0.6915	0.6950	0.6985	0.7019	0.7054					
0.60	0.7257	0.7291	0.7324	0.7357	0.7389					
0.70	0.7580	0.7611	0.7642	0.7673	0.7704					
0.80	0.7881	0.7910	0.7939	0.7967	0.7995					
0.90	0.8159	0.8186	0.8212	0.8238	0.8264					
1.00	0.8413	0.8438	0.8461	0.8485	0.8508					
1.10	0.8643	0.8665	0.8686	0.8708	0.8729					
1.20	0.8849	0.8869	0.8888	0.8907	0.8925					
1.30	0.9032	0.9049	0.9066	0.9082	0.9099					
1.40	0.9192	0.9207	0.9222	0.9236	0.9251					
1.50	0.9332	0.9345	0.9357	0.9370	0.9382					
1.60	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.70	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.80	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.90	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.00	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.10	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.20	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.30	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.40	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.50	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.60	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.70	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.80	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.90	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.00	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.10	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.20	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.30	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.40	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

Przykładowe wartości:

p $z_p = \Phi^{-1}(p)$

0.95 1.64

0.975 1.96

0.99 2.33

0.995 2.58

Kwantyl z_p dla $Z \sim N(0, 1)$ a tablica wartości $\Phi(z)$

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.00	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.10	0.5398	0.5438	0.5478	0.5517	0.5557					
0.20	0.5793	0.5832	0.5871	0.5910	0.5948					
0.30	0.6179	0.6217	0.6255	0.6293	0.6331					
0.40	0.6554	0.6591	0.6628	0.6664	0.6700					
0.50	0.6915	0.6950	0.6985	0.7019	0.7054					
0.60	0.7257	0.7291	0.7324	0.7357	0.7389					
0.70	0.7580	0.7611	0.7642	0.7673	0.7704					
0.80	0.7881	0.7910	0.7939	0.7967	0.7995					
0.90	0.8159	0.8186	0.8212	0.8238	0.8264					
1.00	0.8413	0.8438	0.8461	0.8485	0.8508					
1.10	0.8643	0.8665	0.8686	0.8708	0.8729					
1.20	0.8849	0.8869	0.8888	0.8907	0.8925					
1.30	0.9032	0.9049	0.9066	0.9082	0.9099					
1.40	0.9192	0.9207	0.9222	0.9236	0.9251					
1.50	0.9332	0.9345	0.9357	0.9370	0.9382					
1.60	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.70	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.80	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.90	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.00	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.10	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9858
2.20	0.9861	0.9864	0.9868	0.9871	0.9874	0.9877	0.9880	0.9883	0.9886	0.9889
2.30	0.9893	0.9896	0.9898	0.9901	0.9903	0.9905	0.9907	0.9909	0.9911	0.9913
2.40	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9933	0.9935	0.9937
2.50	0.9938	0.9940	0.9941	0.9943	0.9944	0.9946	0.9947	0.9948	0.9949	0.9950
2.60	0.9953	0.9955	0.9956	0.9957	0.9958	0.9959	0.9960	0.9961	0.9962	0.9963
2.70	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.80	0.9974	0.9975	0.9976	0.9977	0.9978	0.9979	0.9980	0.9981	0.9982	0.9983
2.90	0.9981	0.9982	0.9982	0.9983	0.9984	0.9985	0.9986	0.9987	0.9988	0.9989
3.00	0.9987	0.9987	0.9987	0.9988	0.9989	0.9990	0.9990	0.9991	0.9991	0.9992
3.10	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9993	0.9993	0.9994	0.9994
3.20	0.9993	0.9993	0.9994	0.9994	0.9995	0.9995	0.9996	0.9996	0.9997	0.9997
3.30	0.9995	0.9995	0.9995	0.9996	0.9996	0.9997	0.9997	0.9997	0.9998	0.9998
3.40	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

Przykładowe wartości:

p	$z_p = \Phi^{-1}(p)$
0.95	1.64
0.975	1.96
0.99	2.33
0.995	2.58

Przykładowe wartości:

α	$z_{1-\alpha/2} = \Phi^{-1}(1 - \alpha/2)$
0.1	1.64
0.05	1.96
0.02	2.33
0.01	2.58

Przykład: rozkład normalny ze znaną wariancją

Próba o liczności $n = 16$ pomiarów pewnej cechy o rozkładzie normalnym ze znaną wariancją $\sigma^2 = 16$ dała wartość statystyki $\bar{x}_n = 2$. Wyznacz przedział ufności dla wartości oczekiwanej na poziomie ufności $1 - \alpha$ dla $\alpha = 0.05$.

Przykład: rozkład normalny ze znaną wariancją

Próba o liczności $n = 16$ pomiarów pewnej cechy o rozkładzie normalnym ze znaną wariancją $\sigma^2 = 16$ dała wartość statystyki $\bar{x}_n = 2$. Wyznacz przedział ufności dla wartości oczekiwanej na poziomie ufności $1 - \alpha$ dla $\alpha = 0.05$.

Rozwiązanie: Przedział ufności ma postać:

$$[\bar{x}_n - \Delta, \bar{x}_n + \Delta], \quad \text{gdzie } \Delta = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

Przykład: rozkład normalny ze znaną wariancją

Próba o liczności $n = 16$ pomiarów pewnej cechy o rozkładzie normalnym ze znaną wariancją $\sigma^2 = 16$ dała wartość statystyki $\bar{x}_n = 2$. Wyznacz przedział ufności dla wartości oczekiwanej na poziomie ufności $1 - \alpha$ dla $\alpha = 0.05$.

Rozwiązanie: Przedział ufności ma postać:

$$[\bar{x}_n - \Delta, \bar{x}_n + \Delta], \quad \text{gdzie } \Delta = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

$$z_{1-\alpha/2} = z_{0.975} = \Phi^{-1}(0.975) = 1.96$$

Przykład: rozkład normalny ze znaną wariancją

Próba o liczności $n = 16$ pomiarów pewnej cechy o rozkładzie normalnym ze znaną wariancją $\sigma^2 = 16$ dała wartość statystyki $\bar{x}_n = 2$. Wyznacz przedział ufności dla wartości oczekiwanej na poziomie ufności $1 - \alpha$ dla $\alpha = 0.05$.

Rozwiązanie: Przedział ufności ma postać:

$$[\bar{x}_n - \Delta, \bar{x}_n + \Delta], \quad \text{gdzie } \Delta = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

$$z_{1-\alpha/2} = z_{0.975} = \Phi^{-1}(0.975) = 1.96$$

$$\Delta = 1.96 \frac{4}{\sqrt{16}} = 1.96$$

Przykład: rozkład normalny ze znaną wariancją

Próba o liczności $n = 16$ pomiarów pewnej cechy o rozkładzie normalnym ze znaną wariancją $\sigma^2 = 16$ dała wartość statystyki $\bar{x}_n = 2$. Wyznacz przedział ufności dla wartości oczekiwanej na poziomie ufności $1 - \alpha$ dla $\alpha = 0.05$.

Rozwiązanie: Przedział ufności ma postać:

$$[\bar{x}_n - \Delta, \bar{x}_n + \Delta], \quad \text{gdzie } \Delta = z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

$$z_{1-\alpha/2} = z_{0.975} = \Phi^{-1}(0.975) = 1.96$$

$$\Delta = 1.96 \frac{4}{\sqrt{16}} = 1.96$$

$$[\bar{x}_n - \Delta, \bar{x}_n + \Delta] = [2 - 1.96, 2 + 1.96] = [0.04, 3.96]$$

Przykład: rozkład dwupunktowy

Niech $X \sim B(p)$. Znajdziemy przedział ufności dla parametru p .

Przykład: rozkład dwupunktowy

Niech $X \sim B(p)$. Znajdziemy przedział ufności dla parametru p .

Estymator parametru p na podstawie próby X_1, \dots, X_n :

$$\hat{p} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{\# \text{ sukcesów}}{n}$$

Przykład: rozkład dwupunktowy

Niech $X \sim B(p)$. Znajdziemy przedział ufności dla parametru p .

Estymator parametru p na podstawie próby X_1, \dots, X_n :

$$\hat{p} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{\# \text{ sukcesów}}{n}$$

$$E(\hat{p}) = p, \quad D^2(\hat{p}) = \frac{D^2(X)}{n} = \frac{p(1-p)}{n},$$

Przykład: rozkład dwupunktowy

Niech $X \sim B(p)$. Znajdziemy przedział ufności dla parametru p .

Estymator parametru p na podstawie próby X_1, \dots, X_n :

$$\hat{p} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{\# \text{ sukcesów}}{n}$$

$$E(\hat{p}) = p, \quad D^2(\hat{p}) = \frac{D^2(X)}{n} = \frac{p(1-p)}{n},$$

Z Centralnego Twierdzenia Granicznego mamy:

$$\frac{\hat{p} - E(\hat{p})}{D(\hat{p})} = \frac{\hat{p} - p}{\sqrt{p(1-p)}} \sqrt{n} \xrightarrow{D} Z \sim N(0, 1)$$

Przykład: rozkład dwupunktowy

Niech $X \sim B(p)$. Znajdziemy przedział ufności dla parametru p .

Estymator parametru p na podstawie próby X_1, \dots, X_n :

$$\hat{p} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{\# \text{ sukcesów}}{n}$$

$$E(\hat{p}) = p, \quad D^2(\hat{p}) = \frac{D^2(X)}{n} = \frac{p(1-p)}{n},$$

Z Centralnego Twierdzenia Granicznego mamy:

$$\frac{\hat{p} - E(\hat{p})}{D(\hat{p})} = \frac{\hat{p} - p}{\sqrt{p(1-p)}} \sqrt{n} \xrightarrow{D} Z \sim N(0, 1)$$

Z kolei z Prawa Wielkich Liczb mamy $\hat{p} \xrightarrow{P} p$, a tym samym*:

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})}} \sqrt{n} \xrightarrow{D} Z \sim N(0, 1)$$

Załóżymy, że n jest wystarczająco duże aby skorzystać z tego przybliżenia.

* nietrywialne: jeśli $X_n \xrightarrow{D} X$ i $Y_n \xrightarrow{P} c$ to $X_n f(Y_n) \xrightarrow{D} X f(c)$ dla ciągłej f .

Przykład: rozkład dwupunktowy

Konstruujemy przedział ufności na poziomie ufności $1 - \alpha$:

$$1 - \alpha = P(-\Delta \leq \hat{p} - p \leq \Delta)$$

Przykład: rozkład dwupunktowy

Konstruujemy przedział ufności na poziomie ufności $1 - \alpha$:

$$\begin{aligned} 1 - \alpha &= P(-\Delta \leq \hat{p} - p \leq \Delta) \\ &= P\left(-\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}} \leq \underbrace{\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})}}\sqrt{n}}_{\simeq Z} \leq \frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) \end{aligned}$$

Przykład: rozkład dwupunktowy

Konstruujemy przedział ufności na poziomie ufności $1 - \alpha$:

$$\begin{aligned}1 - \alpha &= P(-\Delta \leq \hat{p} - p \leq \Delta) \\&= P\left(-\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}} \leq \underbrace{\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})}}\sqrt{n}}_{\simeq Z} \leq \frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) \\&\simeq \Phi\left(\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) - \Phi\left(-\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) = 2\Phi\left(\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) - 1\end{aligned}$$

Przykład: rozkład dwupunktowy

Konstruujemy przedział ufności na poziomie ufności $1 - \alpha$:

$$\begin{aligned}1 - \alpha &= P(-\Delta \leq \hat{p} - p \leq \Delta) \\&= P\left(-\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}} \leq \underbrace{\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})}}\sqrt{n}}_{\simeq Z} \leq \frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) \\&\simeq \Phi\left(\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) - \Phi\left(-\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) = 2\Phi\left(\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) - 1\end{aligned}$$

Rozwiązując równanie otrzymujemy:

$$\Delta = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Przykład: rozkład dwupunktowy

Konstruujemy przedział ufności na poziomie ufności $1 - \alpha$:

$$\begin{aligned}1 - \alpha &= P(-\Delta \leq \hat{p} - p \leq \Delta) \\&= P\left(-\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}} \leq \underbrace{\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})}}\sqrt{n}}_{\simeq Z} \leq \frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) \\&\simeq \Phi\left(\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) - \Phi\left(-\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) = 2\Phi\left(\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) - 1\end{aligned}$$

Rozwiązując równanie otrzymujemy:

$$\Delta = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Zadanie 2

Rozwiąż powyższe zagadnienie krok po kroku

Przykład: rozkład dwupunktowy

W celu oszacowania poparcia kandydata A w drugiej turze wyborów prezydenckich pobrano losowo próbę o liczności $n = 1000$ osób, odnotowując czy dana osoba głosuje na kandydata A ($X = 1$), czy na jego konkurenta B ($X = 0$). Uzyskano 550 głosów za A i 450 głosów za B . Wyznacz przedział ufności dla poparcia kandydata A dla $\alpha = 0.05$.

Przykład: rozkład dwupunktowy

W celu oszacowania poparcia kandydata A w drugiej turze wyborów prezydenckich pobrano losowo próbę o liczności $n = 1000$ osób, odnotowując czy dana osoba głosuje na kandydata A ($X = 1$), czy na jego konkurenta B ($X = 0$). Uzyskano 550 głosów za A i 450 głosów za B . Wyznacz przedział ufności dla poparcia kandydata A dla $\alpha = 0.05$.

Rozwiązanie:

$$\hat{p} = \frac{550}{1000} = 0.55$$

Przykład: rozkład dwupunktowy

W celu oszacowania poparcia kandydata A w drugiej turze wyborów prezydenckich pobrano losowo próbę o liczności $n = 1000$ osób, odnotowując czy dana osoba głosuje na kandydata A ($X = 1$), czy na jego konkurenta B ($X = 0$). Uzyskano 550 głosów za A i 450 głosów za B . Wyznacz przedział ufności dla poparcia kandydata A dla $\alpha = 0.05$.

Rozwiązanie:

$$\hat{p} = \frac{550}{1000} = 0.55$$

$$z_{1-\alpha/2} = z_{0.975} = \Phi^{-1}(0.975) = 1.96$$

Przykład: rozkład dwupunktowy

W celu oszacowania poparcia kandydata A w drugiej turze wyborów prezydenckich pobrano losowo próbę o liczności $n = 1000$ osób, odnotowując czy dana osoba głosuje na kandydata A ($X = 1$), czy na jego konkurenta B ($X = 0$). Uzyskano 550 głosów za A i 450 głosów za B . Wyznacz przedział ufności dla poparcia kandydata A dla $\alpha = 0.05$.

Rozwiązanie:

$$\hat{p} = \frac{550}{1000} = 0.55$$

$$z_{1-\alpha/2} = z_{0.975} = \Phi^{-1}(0.975) = 1.96$$

$$\Delta = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = 1.96 \sqrt{\frac{0.55 \cdot 0.45}{1000}} \simeq 0.031$$

Przykład: rozkład dwupunktowy

W celu oszacowania poparcia kandydata A w drugiej turze wyborów prezydenckich pobrano losowo próbę o liczności $n = 1000$ osób, odnotowując czy dana osoba głosuje na kandydata A ($X = 1$), czy na jego konkurenta B ($X = 0$). Uzyskano 550 głosów za A i 450 głosów za B . Wyznacz przedział ufności dla poparcia kandydata A dla $\alpha = 0.05$.

Rozwiązanie:

$$\hat{p} = \frac{550}{1000} = 0.55$$

$$z_{1-\alpha/2} = z_{0.975} = \Phi^{-1}(0.975) = 1.96$$

$$\Delta = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = 1.96 \sqrt{\frac{0.55 \cdot 0.45}{1000}} \simeq 0.031$$

$$[\hat{p} - \Delta, \hat{p} + \Delta] = [0.55 - 0.031, 0.55 + 0.031] = [0.519, 0.581]$$

Przykład: rozkład normalny z nieznaną wariancją

Niech $X \sim N(\mu, \sigma^2)$, ale teraz **nie znamy** σ^2

Przykład: rozkład normalny z nieznaną wariancją

Niech $X \sim N(\mu, \sigma^2)$, ale teraz **nie znamy** σ^2

Jak poprzednio, jako estymator wartości oczekiwanej μ wybieramy $\hat{\mu} = \bar{X}_n$

Przykład: rozkład normalny z nieznaną wariancją

Niech $X \sim N(\mu, \sigma^2)$, ale teraz **nie znamy** σ^2

Jak poprzednio, jako estymator wartości oczekiwanej μ wybieramy $\hat{\mu} = \bar{X}_n$

Ponieważ nie znamy wariancji σ^2 , **estymujemy ją z próby**:

$$\hat{\sigma}_*^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Przykład: rozkład normalny z nieznaną wariancją

Niech $X \sim N(\mu, \sigma^2)$, ale teraz **nie znamy** σ^2

Jak poprzednio, jako estymator wartości oczekiwanej μ wybieramy $\hat{\mu} = \bar{X}_n$

Ponieważ nie znamy wariancji σ^2 , **estymujemy ją z próby**:

$$\hat{\sigma}_*^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Wprowadzamy nową zmienną:

$$T = \frac{\bar{X}_n - \mu}{\hat{\sigma}_*} \sqrt{n}$$

Przykład: rozkład normalny z nieznaną wariancją

Niech $X \sim N(\mu, \sigma^2)$, ale teraz **nie znamy** σ^2

Jak poprzednio, jako estymator wartości oczekiwanej μ wybieramy $\hat{\mu} = \bar{X}_n$

Ponieważ nie znamy wariancji σ^2 , **estymujemy ją z próby**:


$$\hat{\sigma}_*^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Wprowadzamy nową zmienną:


$$T = \frac{\bar{X}_n - \mu}{\hat{\sigma}_*} \sqrt{n}$$

Można pokazać, że zmienna T ma **rozkład t -Studenta** o $n - 1$ stopniach swobody

Rozkład t -Studenta o k stopniach swobody



Rozkład t -Studenta o k stopniach swobody



Dla $k \rightarrow \infty$ rozkład t zbiega do rozkładu $N(0, 1)$

Przykład: rozkład normalny z nieznaną wariancją

$$1 - \alpha = P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right)$$

Przykład: rozkład normalny z nieznaną wariancją

$$\begin{aligned}1 - \alpha &= P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right) \\&= P\left(-\frac{\Delta}{\hat{\sigma}_*} \sqrt{n} \leq \frac{\bar{X}_n - \mu}{\hat{\sigma}_*} \sqrt{n} \leq \frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right)\end{aligned}$$

Przykład: rozkład normalny z nieznaną wariancją

$$\begin{aligned}1 - \alpha &= P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right) \\&= P\left(-\frac{\Delta}{\hat{\sigma}_*} \sqrt{n} \leq \frac{\bar{X}_n - \mu}{\hat{\sigma}_*} \sqrt{n} \leq \frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) \\&= P\left(-\frac{\Delta}{\hat{\sigma}_*} \sqrt{n} \leq T \leq \frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right)\end{aligned}$$

Przykład: rozkład normalny z nieznaną wariancją

$$\begin{aligned}1 - \alpha &= P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right) \\&= P\left(-\frac{\Delta}{\hat{\sigma}_*} \sqrt{n} \leq \frac{\bar{X}_n - \mu}{\hat{\sigma}_*} \sqrt{n} \leq \frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) \\&= P\left(-\frac{\Delta}{\hat{\sigma}_*} \sqrt{n} \leq T \leq \frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) \\&= F_T\left(\frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) - F_T\left(-\frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) = 2F_T\left(\frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) - 1,\end{aligned}$$

gdzie użyliśmy symetrii rozkładu t -Studenta: $F_T(-x) = 1 - F_T(x)$.

Przykład: rozkład normalny z nieznaną wariancją

$$\begin{aligned}1 - \alpha &= P\left(-\Delta \leq \bar{X}_n - \mu \leq \Delta\right) \\&= P\left(-\frac{\Delta}{\hat{\sigma}_*} \sqrt{n} \leq \frac{\bar{X}_n - \mu}{\hat{\sigma}_*} \sqrt{n} \leq \frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) \\&= P\left(-\frac{\Delta}{\hat{\sigma}_*} \sqrt{n} \leq T \leq \frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) \\&= F_T\left(\frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) - F_T\left(-\frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) = 2F_T\left(\frac{\Delta}{\hat{\sigma}_*} \sqrt{n}\right) - 1,\end{aligned}$$

gdzie użyliśmy symetrii rozkładu t -Studenta: $F_T(-x) = 1 - F_T(x)$.

Postępując analogicznie do przypadku znanej wariancji dostajemy:

$$\Delta = t_{1-\alpha/2; n-1} \frac{\hat{\sigma}_*}{\sqrt{n}}, \quad \text{gdzie } t_{1-\alpha/2; n-1} = F_T^{-1}\left(1 - \frac{\alpha}{2}\right)$$

jest kwantylem rzędu $1 - \frac{\alpha}{2}$ rozkładu t -Studenta o $n - 1$ stopniach swobody

Przykładowa tablica kwantyli rozkładu t -Studenta


df	$t_{.90}$	$t_{.95}$	$t_{.975}$	$t_{.99}$	$t_{.995}$
1	3.078	6.314	12.706	31.821	63.657
2	1.886	2.920	4.303	6.965	9.925
3	1.638	2.353	3.182	4.541	5.841
4	1.533	2.132	2.776	3.747	4.604
5	1.476	2.015	2.571	3.365	4.032
6	1.440	1.943	2.447	3.143	3.707
7	1.415	1.895	2.365	2.998	3.499
8	1.397	1.860	2.306	2.896	3.355
9	1.383	1.833	2.262	2.821	3.250
10	1.372	1.812	2.228	2.764	3.169
11	1.363	1.796	2.201	2.718	3.106
12	1.356	1.782	2.179	2.681	3.055
13	1.350	1.771	2.160	2.650	3.012
14	1.345	1.761	2.145	2.624	2.977
15	1.341	1.753	2.131	2.602	2.947
16	1.337	1.746	2.120	2.583	2.921
17	1.333	1.740	2.110	2.567	2.898
18	1.330	1.734	2.101	2.552	2.878
19	1.328	1.729	2.093	2.539	2.861
20	1.325	1.725	2.086	2.528	2.845
21	1.323	1.721	2.080	2.518	2.831
22	1.321	1.717	2.074	2.508	2.819
23	1.319	1.714	2.069	2.500	2.807
24	1.318	1.711	2.064	2.492	2.797
25	1.316	1.708	2.060	2.485	2.787
26	1.315	1.706	2.056	2.479	2.779
27	1.314	1.703	2.052	2.473	2.771
28	1.313	1.701	2.048	2.467	2.763
29	1.311	1.699	2.045	2.462	2.756
30	1.310	1.697	2.042	2.457	2.750
32	1.309	1.694	2.037	2.449	2.738
34	1.307	1.691	2.032	2.441	2.728
36	1.306	1.688	2.028	2.434	2.719
38	1.304	1.686	2.024	2.429	2.712
∞	1.282	1.645	1.960	2.326	2.576

Przykładowa tablica kwantyli rozkładu t -Studenta


df	$t_{.90}$	$t_{.95}$	$t_{.975}$	$t_{.99}$	$t_{.995}$
1	3.078	6.314	12.706	31.821	63.657
2				6.965	9.925
3				4.541	5.841
4				3.747	4.604
5				3.365	4.032
6	1.440	1.943	2.447	3.143	3.707
7	1.415	1.895	2.365	2.998	3.499
8	1.397	1.860	2.306	2.896	3.355
9	1.383	1.833	2.262	2.821	3.250
10	1.372	1.812	2.228	2.764	3.169
11	1.363	1.796	2.201	2.718	3.106
12	1.356	1.782	2.179	2.681	3.055
13	1.350	1.771	2.160	2.650	3.012
14	1.345	1.761	2.145	2.624	2.977
15	1.341	1.753	2.131	2.602	2.947
16	1.337	1.746	2.120	2.583	2.921
17	1.333	1.740	2.110	2.567	2.898
18	1.330	1.734	2.101	2.552	2.878
19	1.328	1.729	2.093	2.539	2.861
20	1.325	1.725	2.086	2.528	2.845
21	1.323	1.721	2.080	2.518	2.831
22	1.321	1.717	2.074	2.508	2.819
23	1.319	1.714	2.069	2.500	2.807
24	1.318	1.711	2.064	2.492	2.797
25	1.316	1.708	2.060	2.485	2.787
26	1.315	1.706	2.056	2.479	2.779
27	1.314	1.703	2.052	2.473	2.771
28	1.313	1.701	2.048	2.467	2.763
29	1.311	1.699	2.045	2.462	2.756
30	1.310	1.697	2.042	2.457	2.750
32	1.309	1.694	2.037	2.449	2.738
34	1.307	1.691	2.032	2.441	2.728
36	1.306	1.688	2.028	2.434	2.719
38	1.304	1.686	2.024	2.429	2.712
∞	1.282	1.645	1.960	2.326	2.576

Liczba stopni swobody k
(df – degrees of freedom)

Rozkład t -Studenta



Rozkład t -Studenta



Kwantyle rozkładu t -Studenta są nieznacznie większe od odpowiadających im kwantyli rozkładu normalnego (rozkład t -Studenta ma grubsze ogony). Jest to spowodowane estymowaniem wariancji z danych (zwiększa niepewność przy konstrukcji przedziału ufności)

Przykład: rozkład normalny z nieznaną wariancją

Próba o liczności $n = 16$ pomiarów pewnej cechy o rozkładzie normalnym statystyki $\bar{x}_n = 1$ oraz $\hat{s}_*^2 = 9$. Wyznacz przedział ufności dla wartości oczekiwanej na poziomie ufności $1 - \alpha$ dla $\alpha = 0.05$.

Przykład: rozkład normalny z nieznaną wariancją

Próba o liczności $n = 16$ pomiarów pewnej cechy o rozkładzie normalnym statystyki $\bar{x}_n = 1$ oraz $\hat{s}_*^2 = 9$. Wyznacz przedział ufności dla wartości oczekiwanej na poziomie ufności $1 - \alpha$ dla $\alpha = 0.05$.

Rozwiązanie: Przedział ufności ma postać:

$$[\bar{x}_n - \Delta, \bar{x}_n + \Delta], \quad \text{gdzie } \Delta = t_{1-\alpha/2; n-1} \frac{\hat{s}_*}{\sqrt{n}}$$

Przykład: rozkład normalny z nieznaną wariancją

Próba o liczności $n = 16$ pomiarów pewnej cechy o rozkładzie normalnym statystyki $\bar{x}_n = 1$ oraz $\hat{s}_*^2 = 9$. Wyznacz przedział ufności dla wartości oczekiwanej na poziomie ufności $1 - \alpha$ dla $\alpha = 0.05$.

Rozwiązanie: Przedział ufności ma postać:

$$[\bar{x}_n - \Delta, \bar{x}_n + \Delta], \quad \text{gdzie } \Delta = t_{1-\alpha/2; n-1} \frac{\hat{s}_*}{\sqrt{n}}$$

$$t_{1-\alpha/2; n-1} = t_{0.975; 15} = 2.131$$

Przykład: rozkład normalny z nieznaną wariancją

Próba o liczności $n = 16$ pomiarów pewnej cechy o rozkładzie normalnym statystyki $\bar{x}_n = 1$ oraz $\hat{s}_*^2 = 9$. Wyznacz przedział ufności dla wartości oczekiwanej na poziomie ufności $1 - \alpha$ dla $\alpha = 0.05$.

Rozwiązanie: Przedział ufności ma postać:

$$[\bar{x}_n - \Delta, \bar{x}_n + \Delta], \quad \text{gdzie } \Delta = t_{1-\alpha/2; n-1} \frac{\hat{s}_*}{\sqrt{n}}$$

$$t_{1-\alpha/2; n-1} = t_{0.975; 15} = 2.131$$

$$\Delta = 2.145 \frac{3}{\sqrt{16}} = 1.609$$

Przykład: rozkład normalny z nieznaną wariancją

Próba o liczności $n = 16$ pomiarów pewnej cechy o rozkładzie normalnym statystyki $\bar{x}_n = 1$ oraz $\hat{s}_*^2 = 9$. Wyznacz przedział ufności dla wartości oczekiwanej na poziomie ufności $1 - \alpha$ dla $\alpha = 0.05$.

Rozwiązanie: Przedział ufności ma postać:

$$[\bar{x}_n - \Delta, \bar{x}_n + \Delta], \quad \text{gdzie } \Delta = t_{1-\alpha/2; n-1} \frac{\hat{s}_*}{\sqrt{n}}$$

$$t_{1-\alpha/2; n-1} = t_{0.975; 15} = 2.131$$

$$\Delta = 2.145 \frac{3}{\sqrt{16}} = 1.609$$

$$[\bar{x}_n - \Delta, \bar{x}_n + \Delta] = [1 - 1.609, 1 + 1.609] = [-0.609, 2.609]$$