

# Metody probabilistyczne

## Rozwiązania zadań

### 13. Statystyka 2

16.01.2018

**Zadanie 1.** Wyznacz estymator największej wiarygodności parametru  $\lambda$  dla rozkładu Poissona.

*Odpowiedź:* Rozkład Poissona zdefiniowany jest jako:

$$p_\lambda(x) = \frac{\lambda^x}{x!} e^{-\lambda}, \quad \text{dla } x = 0, 1, 2, \dots,$$

gdzie przez  $p_\lambda(x)$  oznaczamy skrótowo  $P_\lambda(X = x)$ . Załóżmy teraz, że zaobserwowaliśmy dane  $\mathbf{x} = (x_1, x_2, \dots, x_n)$ . Funkcja wiarygodności (łącznie prawdopodobieństwo zaobserwowanych danych) ma postać:

$$L(\mathbf{x}; \lambda) = \prod_{i=1}^n p_\lambda(x_i) = \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{1}{x_1! x_2! \cdots x_n!} \lambda^{x_1 + x_2 + \dots + x_n} e^{-n\lambda}.$$

Oznaczając jak zwykle  $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$ , możemy przepisać:

$$L(\mathbf{x}; \lambda) = \frac{1}{x_1! x_2! \cdots x_n!} \lambda^{n\bar{x}_n} e^{-n\lambda},$$

co po zlogarytmowaniu i przemnożeniu przez minus jeden daje:

$$-\ln L(\mathbf{x}; \lambda) = \ln(x_1! \cdots x_n!) + n\bar{x}_n \ln \lambda - n\lambda.$$

Pierwszy człon jest niezależny od  $\lambda$ , więc zniknie przy braniu pochodnej. Różniczkując po  $\lambda$  dostajemy:

$$\frac{\partial}{\partial \lambda} -\ln L(\mathbf{x}; \lambda) = n\bar{x}_n \frac{1}{\lambda} - n.$$

Przyrównanie pochodnej do zera daje:

$$\lambda = \bar{x}_n,$$

a więc estymatorem największej wiarygodności parametru  $\lambda$  jest po prostu średnia arytmetyczna z próby:  $\hat{\lambda} = \bar{X}_n$ .

**Zadanie 2\*.** Skonstruuj przedział ufności dla parametru  $p$  w rozkładzie dwupunktowym  $B(p)$ . Użyj przybliżenia rozkładem normalnym.

*Odpowiedź:* Niech  $X \sim B(p)$  ma rozkład dwupunktowy. Znajdziemy przedział ufności dla parametru  $p$ . Estymator punktowy parametru  $p$  na podstawie próby  $X_1, \dots, X_n$  ma postać:

$$\hat{p} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Ponieważ  $X_i \in \{0, 1\}$ , łatwo zauważyć, że  $\hat{p}$  jest równe liczbie sukcesów podzielonej przez  $n$ , czyli empirycznej (wyznaczonej na próbie) częstości sukcesów. Ponieważ  $\hat{p}$  jest również średnią arytmetyczną z próby, mamy:

$$\begin{aligned} E(\hat{p}) &= E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \underbrace{E(X_i)}_p = p, \\ D^2(\hat{p}) &= D^2\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \underbrace{D^2(X_i)}_{p(1-p)} = \frac{p(1-p)}{n}, \end{aligned}$$

gdzie we wzorze na wariancję wykorzystaliśmy niezależność zmiennych  $X_1, \dots, X_n$ . Z Centralnego Twierdzenia Granicznego wiemy, że ciąg ustandaryzowanych średnich arytmetycznych zbiega (według dystrybuant) do zmiennej o rozkładzie normalnym standardowym  $N(0, 1)$ , tzn. że:

$$\frac{\hat{p} - E(\hat{p})}{D(\hat{p})} = \frac{\hat{p} - p}{\sqrt{p(1-p)}} \sqrt{n} \xrightarrow{D} Z \sim N(0, 1) \quad (1)$$

Z kolei z Prawa Wielkich Liczb wiemy, że średnia arytmetyczna zbiega do wartości oczekiwanej:

$$\hat{p} \xrightarrow{P} E(X) = p.$$

Tym samym, możemy<sup>1</sup> w mianowniku (1) zastąpić  $p$  przez  $\hat{p}$  i nadal otrzymamy zbieżność według dystrybuant do  $Z \sim N(0, 1)$ :

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})}} \sqrt{n} \xrightarrow{D} Z \sim N(0, 1).$$

Założymy, że  $n$  jest wystarczająco duże i użyjemy powyższej własności do przybliżenia rozkładem normalnym, tzn. przybliżymy:

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})}} \sqrt{n} \simeq Z \sim N(0, 1) \quad (2)$$

Konstruujemy przedział ufności na poziomie ufności  $1 - \alpha$ :

$$\begin{aligned} 1 - \alpha &= P(-\Delta \leq \hat{p} - p \leq \Delta) \\ &= P\left(-\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}} \leq \underbrace{\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})}} \sqrt{n}}_{\simeq Z \text{ (używamy (2))}} \leq \frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) \\ &= P\left(-\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}} \leq Z \leq \frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) \\ &\simeq \Phi\left(\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) - \Phi\left(-\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) = 2\Phi\left(\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) - 1, \end{aligned}$$

gdzie w ostatniej linii wykorzystaliśmy własność dystrybuanty rozkładu normalnego standardowego  $\Phi(-x) = 1 - \Phi(x)$  dla dowolnych  $x$ . Otrzymaliśmy więc równanie:

$$1 - \alpha = 2\Phi\left(\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) - 1,$$

co po dodaniu stronami 1 i podzieleniu przez 2 daje:

$$\Phi\left(\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}}\right) = 1 - \frac{\alpha}{2}.$$

Ponieważ  $\Phi$  jest odwracalna, otrzymujemy:

$$\frac{\Delta\sqrt{n}}{\sqrt{\hat{p}(1-\hat{p})}} = \underbrace{\Phi^{-1}\left(1 - \frac{\alpha}{2}\right)}_{z_{1-\alpha/2}} \implies \Delta = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

Zauważmy, że  $z_{1-\alpha/2}$  jest kwantylem rzędu  $1 - \frac{\alpha}{2}$  rozkładu normalnego standardowego. Tym samym wyznaczyliśmy przybliżony przedział ufności na poziomie ufności  $1 - \alpha$ :

$$[\hat{p} - \Delta, \hat{p} + \Delta], \quad \text{gdzie } \Delta = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

---

<sup>1</sup>Uwaga: stwierdzenie to jest nietrywialne. Wymaga użycia dwóch twierdzeń: (1) jeśli  $Y_n \xrightarrow{P} c$  to dla dowolnej funkcji ciągłej  $f$  mamy  $f(Y_n) \xrightarrow{P} f(c)$ ; (2) jeśli  $X_n \xrightarrow{D} X$  i  $Z_n \xrightarrow{P} a$  to  $X_n Z_n \xrightarrow{D} aX$ . Używamy powyższych twierdzeń biorąc  $Y_n = \bar{X}_n = \hat{p} \xrightarrow{P} p$ ,  $f(x) = \frac{\sqrt{p(1-p)}}{\sqrt{x(1-x)}}$ , oraz  $Z_n = f(Y_n)$ , tym samym  $Z_n = \frac{\sqrt{p(1-p)}}{\sqrt{\hat{p}(1-\hat{p})}} \xrightarrow{P} f(p) = 1$ . Na koniec bierzemy  $X_n = \frac{\hat{p}-p}{\sqrt{p(1-p)}} \sqrt{n} \xrightarrow{D} N(0, 1)$ , co po wykorzystaniu drugiego twierdzenia daje:  $\frac{\hat{p}-p}{\sqrt{\hat{p}(1-\hat{p})}} \sqrt{n} = X_n Z_n \xrightarrow{D} N(0, 1)$ .